

ReguMate 系统评测报告

生成时间: 2026-07-22T09:27:40.798148+00:00; 阶段 5 质量回归更新: 2026-07-24

本报告基于项目中已保存的真实实验产物重新汇总生成。报告中的数值均来自 JSON/Markdown 结果文件或本次聚合脚本的确定性重算；无法从现有文件核实的指标明确标注为“未采集”或“不可计算”。2026-07-24 阶段 5 追加的官方 300 与内部困难集回归单独列示，不覆盖历史 GPU/CPU 基线。

1. 评测背景与目标

ReguMate 面向银行业监管制度、填报说明和统计报表的可信 RAG 问答。评测目标是验证 500 份官方附件入库、300 条官方 QA、证据引用、表格取数、拒答与 CPU/GPU 性能边界。

2. 系统及技术方案概述

系统采用 FastAPI、SQLite 元数据、Qdrant 向量索引、BGE-M3 embedding、BGE reranker 和 OpenAI-compatible 大模型 API。回答链路遵循“检索到 chunk/表格证据才回答；依据不足则拒答”的约束，确定性表格题优先使用结构化单元格证据。

3. 评测环境

项目	值
操作系统/平台	Windows-11-10.0.26200-SP0
Python	3.13.12 (tags/v3.13.12:1cbe481, Feb 3 2026, 18:22:25) [MSC v.1944 64 bit (AMD64)]
Git commit	2038770829adf2a234ba9a2d8266950d44e57015
项目根目录	D:\Agent-Project\ReguMate Agent
环境变量记录	仅记录是否配置 API Key，不输出密钥

4. 硬件与软件配置

已有性能基线文档记录：CPU 为 AMD Ryzen 9 8945HX，16 核/32 线程，内存约 34.1 GB；GPU 为 NVIDIA RTX 5070 Laptop GPU，8 GB 显存。phase1 QA 结果的资源采样峰值如下：

环境	CPU 峰值	RSS 峰值	CUDA allocated 峰值	CUDA reserved 峰值	来源
GPU	434.18%	4.22 GiB	1.07 GiB	1.09 GiB	data/evaluation/performance_experiments/phase1_gpu_full300/contest_qa_all_results.json
CPU	433.94%	0.63 GiB	未采集	未采集	data/evaluation/performance_experiments/phase1_cpu_full300/contest_qa_all_results.json

5. 模型、Embedding、数据库和检索参数

参数	GPU 记录	CPU 记录
selected_mode	gpu	cpu_balanced
backend	pytorch	pytorch
effective_cpu_cores	32	32
embedding_batch_size	4	4
rerank_batch_size	24	4
rerank_max_length	1024	1024
torch_num_threads	16	16
warmup_policy	background	background

Embedding/reranker 为本地 BGE 模型；.env 中的大模型 API 影响 query planning、答案生成和高风险语义核验。本次索引完整性同时引用最终入库清单和 SQLite/Qdrant 审计：当前交付 collection 为 regumate_chunks，Qdrant points 为 46585。

6. 数据集说明

数据集	规模	用途	来源文件
官方附件	500 份	入库、解析、分块、索引完整性	data/contest_dataset/dataset/; data/contest_staging/
官方 QA	300 题	答案准确率、来源命中、分题型/难度、性能	data/contest_dataset/QA数据.xlsx
OOD 派生题	30 题	依据不足拒答	scripts/evaluate_contest_qa.py 从官方题派生

7. 500 份文档入库测试方案

500 份文档入库主结果读取 data/evaluation/final/ingest_manifest.json，该文件记录最终入库运行的文档数、Chunk 数、表格单元格数、向量数和按扩展名/解析器统计。为避免只看解析性能实验导致误判，本报告另读取公式文档重建索引后的 outputs/evaluation/vector_index_audit_after_formula_reindex.json，将冻结 SQLite 中的 document_chunks.chunk_id 与当前 Qdrant payload 中的 chunk_id 做逐项一致性审计。

data/evaluation/performance_experiments/index_parse500.json 只作为解析/分块/SQLite persist/embedding 阶段耗时诊断，不作为主向量数来源；该诊断文件没有保存完整 Qdrant 写入结果，不代表知识库没有向量。

指标公式：入库成功率 = success / processed；平均每文档耗时与阶段耗时来自性能诊断 JSON 的原始耗时字段，并在报告中统一换算为秒。

8. 入库与向量索引结果

数据版本关系说明

为避免将不同实验产物混为同一快照，本报告明确区分官方 300 QA 评分快照、最终入库 manifest 和当前交付环境审计三类证据。三者都用于证明系统能力，但不再被表述为同一次运行的同一 collection。

证据/用途	SQLite / manifest	Qdrant collection / alias	规模	与 300 QA 关系
官方 300 QA 评分快照	QA 结果：data/evaluation/contest_qa_test/20260716_173747/contest_qa_all_results.json；SQLite 路径未在 final_contest_report 中记录	collection=regumate_chunks；alias 未记录；build_id=dev	文档=500；Qdrant points=45651；QA SHA-256=bb43588e9fb45b51a57c61516bc7ff7bd33775863b0828c74212ae69c6395a51	300 道官方 QA 实际使用该快照；这是 QA 准确率、来源命中率和响应时间的主证据
最终入库 manifest	data/evaluation/final/ingest_manifest.json；data_dir=data\evaluation\final_runtime	collection=regumate_contest_v3_build；alias=regumate_contest_v3	文档=500；Chunk/Vector=45530；Cells=133001	用于证明 500 份官方附件可完整入库；不是 final_contest_report 记录的 300 QA 评分 collection
当前交付环境独立审计	SQLite=data/evaluation/final_runtime/app.db；审计文件=outputs/evaluation/vector_index_audit_after_formula_reindex.json；审计时间=2026-07-22T09:27:13.266268+00:00	collection=regumate_chunks；alias 未审计	文档=500；SQLite Chunk=46585；Qdrant points=46585；Dense 维度=1024	用于证明当前交付环境 SQLite chunk_id 与 Qdrant payload chunk_id 完全一致；属于后续交付审计证据

结论：官方 300 QA 使用的是 final_contest_report.json 记录的 regumate_chunks 快照，Qdrant points 为 45,651；regumate_contest_v3_build / regumate_contest_v3 是最终入库 manifest 记录的重建 collection / alias；当前交付环境审计的 regumate_chunks 为 46,585 points。45,530、45,651、46,585 不强行合并为同一口径。差异来自后续交付阶段对解析、分块、表格 chunk 物化和去重规则的迭代，以及审计时间点不同；当前审计中 SQLite 与 Qdrant 的 chunk_id 缺失数和额外数均为 0，未发现当前交付索引缺失写入 Qdrant 的证据。

汇总指标

指标	结果
文档总数	500
成功数量	500
失败数量	0
入库/解析成功率	100.00%
最终入库清单 Chunk 数	45530

指标	结果
表格单元格数	133001
最终入库清单 Vector 数	45530
最终入库 collection	regumate_contest_v3_build
最终入库 alias	regumate_contest_v3
审计 SQLite 文档数	500
审计 SQLite Chunk 数	46585
审计 Qdrant collection	regumate_chunks
审计 Qdrant points	46585
Qdrant unique chunk_id	46585
Qdrant indexed vectors count	70181
Dense 向量维度	1024
Dense 距离度量	Cosine
Sparse 向量启用	True
SQLite/Qdrant chunk_id 一致	是
Qdrant 缺失 chunk_id 数	0
Qdrant 额外 chunk_id 数	0

说明：最终入库清单按运行时 manifest 汇总为 45530 个向量；本次交付环境的独立审计进一步证明 SQLite 中 46585 个 chunk_id 与 Qdrant 中 46585 个 payload chunk_id 完全一致，missing=0、extra=0。indexed_vectors_count 可能大于 points，因为 collection 同时配置 dense 与 sparse 向量。

按文件格式统计：

格式	处理	成功	失败	Chunk	Cells
.doc	32	32	0	1365	0
.docx	34	34	0	5360	0
.pdf	45	45	0	2802	0
.xls	232	232	0	26752	87359
.xlsx	157	157	0	9251	45642

解析性能诊断结果：

指标	结果
诊断文件	data/evaluation/performance_experiments/index_parse500.json

指标	结果
诊断 Chunk 数	46577
诊断 Qdrant 写入结果	未采集（未执行/未保存完整写入口径）
总耗时	2066.75 s
平均每文档耗时	4.11 s
解析阶段平均耗时	1.88 s
分块阶段平均耗时	1.69 s
Embedding 阶段平均耗时	3.89 s
SQLite chunk 持久化平均耗时	0.50 s

9. GPU 与 CPU 入库结果对比

当前没有同一口径的 GPU/CPU 500 文档完整向量入库耗时对比，因此不计算入库加速比；但向量完整性已由最终入库清单和 SQLite/Qdrant 一致性审计补齐。

10. 300 条 QA 评测方案

官方 QA 使用 scripts/evaluate_contest_qa.py 调用后端 /api/qa/ask，并按 source_type、qa_type、difficulty 切片统计。phase1 结果额外捕获后端性能配置、资源采样、引用、context_package 与 manifest_evidence。

核心公式：答案准确率 = answer_correct=True 题数 / 有效题数；来源命中率 = source_hit=True 题数 / 有效题数；引用覆盖率 = 非拒答题 citation_count>0 题数 / 非拒答题数；平均响应时间来自原始响应耗时字段，并在报告中统一换算为秒。

11. QA 总体结果

指标	官方最终 GPU	phase1 GPU	phase1 CPU
题数	300	300	300
完成题数	300	300	300
错误数	0	0	0
答案准确率	100.00%	100.00%	100.00%
来源命中率	100.00%	100.00%	100.00%
引用覆盖率	100.00%	100.00%	100.00%
Grounding 通过率	100.00%	100.00%	100.00%

指标	官方最终 GPU	phase1 GPU	phase1 CPU
Excel 单元格召回率	100.00%	100.00%	100.00%
文本证据覆盖率	86.00%	86.75%	86.75%
文本证据 bigram recall	86.32%	86.29%	86.29%

12. 分题型评测结果

切片	题数	正确数	准确率	平均耗时	P95
单事实检索	134	134	100.00%	3.59 s	7.03 s
多事实检索	66	66	100.00%	4.04 s	6.96 s
表格取数	34	34	100.00%	0.40 s	0.81 s
表格比较	33	33	100.00%	0.41 s	0.68 s
表格计算	33	33	100.00%	0.47 s	0.63 s

13. 分难度评测结果

切片	题数	正确数	准确率	平均耗时	P95
中等	99	99	100.00%	2.29 s	4.17 s
困难	99	99	100.00%	2.85 s	5.39 s
简单	102	102	100.00%	2.76 s	4.41 s

14. 检索效果评测

指标	结果	说明
来源命中率	100.00%	source_hit=True / 总题数
评测口径	离线候选重算	基于已保存候选列表，不等价于重新请求 Qdrant 的在线实验
可评估题数	293	来源：data/evaluation/performance_experiments/phase1_gpu_full300/contest_qa_all_results.json + data/evaluation/performance_experiments/evidence_manifest_seed.json
可评估 aspect 数	469	仅统计 evidence manifest 中有 acceptable_chunk_ids 的 aspect
manifest needs_review 题数	14	需要人工复核，不作为严格 gold 直接计分
无 acceptable chunk 题数	7	单独列出，不并入 Recall@K 分母
无 acceptable chunk aspect 数	20	用于解释分母范围限制
Case Recall@1	88.05%	全部标准 aspect 均在 Top-1 命中

指标	结果	说明
Case Recall@3	92.49%	全部标准 aspect 均在 Top-3 命中
Case Recall@5	98.29%	全部标准 aspect 均在 Top-5 命中
Aspect Recall@1	92.54%	标准 aspect 粒度 Top-1 命中
Aspect Recall@3	95.31%	标准 aspect 粒度 Top-3 命中
Aspect Recall@5	98.93%	标准 aspect 粒度 Top-5 命中
最终上下文 Case Recall	100.00%	acceptable chunk 进入最终 prompt 上下文

检索 TopK 指标由 scripts/evaluate_retrieval_from_results.py 基于已保存 context_package.retrieval_summary.aspect_retrievals[].retrieved_chunks 和 evidence_manifest_seed.json 离线重算；manifest 中 14 题为 needs_review，其中 7 题没有 acceptable chunk，单独列入明细，不并入 Recall@K 分母。scripts/evaluate_online_retrieval_recall.py 已提供直接调用 /api/qa/retrieve 的在线复现实验入口，但必须在后端绑定非空官方 SQLite 与同一 Qdrant collection 后运行，不能用空知识库冒烟结果作为正式指标。

15. 证据引用与可追溯性评测

指标	结果
引用覆盖率	100.00%
Grounding 通过率	100.00%
Reviewed citation accuracy	100.00%
Reviewed citation completeness	100.00%
无效引用案例数	0
缺少行内引用案例数	0
Unsupported entity 案例数	0

16. 表格取数能力评测

指标	结果
Excel 题数	100
Excel 准确率	100.00%
Excel 单元格召回率	100.00%
表格取数准确率	100.00%
表格比较准确率	100.00%
表格计算准确率	100.00%

17. 拒答与幻觉抑制评测

指标	GPU OOD	CPU OOD
题数	30	30
拒答准确率	100.00%	100.00%
答案准确率	100.00%	100.00%
关键实体错误率代理指标	0.00%	0.00%

注意：关键实体错误率代理指标不等价于经人工逐条标注的真实幻觉率。现有数据没有人工逐条幻觉标注；报告使用 key_entity_error_rate 作为代理指标，并同时报告 OOD 拒答准确率。

18. 性能与响应时间评测

环境	平均	P50	P90	P95	最大
GPU	2.63 s	2.75 s	4.18 s	4.73 s	47.86 s
CPU	8.85 s	9.59 s	18.44 s	20.09 s	28.10 s

19. GPU 与 CPU 问答性能对比

指标	GPU	CPU	对比
平均响应时间	2.63 s	8.85 s	CPU/GPU = 3.36x
P95	4.73 s	20.09 s	
准确率	100.00%	100.00%	一致

20. 结论

可核验的官方最终 GPU 报告显示 300/300 完成、答案准确率 100.00%、来源命中率 100.00%，该 QA 快照记录 collection=regumate_chunks、points=45651。phase1 GPU/CPU 300 题均为 100.00% 准确率；GPU 平均响应 2.63 s，CPU 平均响应 8.85 s。500 文档最终入库清单为 500/500 成功、45530 个向量；当前交付环境独立审计证明 SQLite 46585 个 chunk_id 与 Qdrant 46585 个 points 完全匹配，missing=0、extra=0。

2026-07-24 阶段 5 当前代码在 final_runtime/app.db 与 regumate_chunks 上重新通过官方 300 全量回归：300/300，答案准确率、来源命中、Excel 单元格召回、引用覆盖和 Grounding 均为 100%。内部封存困难集 holdout 60 题为 57/60，overall 95.00%，answerable 93.33%，refusal

100%， gate_passed=true。当前执行目标已调整为正确率、引用真实性、拒答准确率和可审计性优先；运行时间只作为参考指标和技术债记录，不作为当前阶段硬性门槛。该 holdout 仍为内部封存困难集，未经过第三方盲测或银行监管专家复核，不应表述为外部专家成绩。

21. 复现方法

从已有结果生成统一评测产物和报告：

```
python scripts\generate_evaluation_report.py --output-dir outputs\evaluation --output docs\系统评测报告.md
```

只汇总入库结果：

```
python scripts\evaluate_ingestion.py --result data\evaluation\final\ingest_manifest.json --output-dir outputs\evaluation
```

审计 SQLite chunk 与 Qdrant payload/vector 一致性：

```
$env:PYTHONIOENCODING='utf-8'
python scripts\audit_vector_index.py --db data\evaluation\final_runtime\app.db --ingest-manifest
data\evaluation\final\ingest_manifest.json --qdrant-url http://127.0.0.1:6333 --collection regumate_chunks --output
outputs\evaluation\vector_index_audit_after_formula_reindex.json
```

从已有 QA 结果生成 QA 指标：

```
python scripts\evaluate_qa.py --from-existing --output-dir outputs\evaluation
```

连接运行中后端重新执行官方 QA：

```
python scripts\evaluate_qa.py --run-backend-eval --dataset data\contest_dataset\QA数据.xlsx --base-url http://127.0.0.1:8000 --device
cuda --split all --output-dir outputs\evaluation
```

CPU/GPU QA 对比：

```
python scripts\compare_cpu_gpu.py --output-dir outputs\evaluation
```

在线检索 Recall 复现实验入口：

```
python scripts\evaluate_online_retrieval_recall.py --base-url http://127.0.0.1:8000 --output-dir outputs\evaluation\online_retrieval
--timeout 240 --resume
```

运行该在线检索脚本前，必须确认 /api/health/ready 绑定的是官方 500 文档 SQLite 与同一 Qdrant collection；空库或不同 collection 只可作为环境诊断，不得计入正式 Recall。

22. 实验结果文件索引

实验	原始结果文件	执行/生成脚本	说明
官方最终 300 QA	data/evaluation/contest_qa_test/20260716_173747/contest_qa_all_results.json	scripts/build_contest_report.py	官方最终口径
phase1 GPU 300 QA	data/evaluation/performance_experiments/phase1_gpu_full300/contest_qa_all_results.json	scripts/evaluate_contest_qa.py	完整引用/context/performance 结果
phase1 CPU 300 QA	data/evaluation/performance_experiments/phase1_cpu_full300/contest_qa_all_results.json	scripts/evaluate_contest_qa.py	CPU 问答性能
GPU OOD 30	data/evaluation/performance_baseline/gpu_20260718_182304/ood/contest_qa_ood_results.json	scripts/evaluate_contest_qa.py --split ood	拒答评测
最终入库 manifest 500	data/evaluation/final/ingest_manifest.json	scripts/ingest_contest_dataset.py	500 文档成功数、Chunk、Cells、Vector
SQLite/Qdrant 向量审计	outputs/evaluation/vector_index_audit_after_formula_reindex.json	scripts/audit_vector_index.py	SQLite chunk_id 与 Qdrant payload chunk_id 一致性
CPU 解析/分块性能诊断 500	data/evaluation/performance_experiments/index_parse500.json	scripts/ingest_contest_dataset.py	解析/分块/SQLite persist/embedding 阶段耗时；不作为向量数来源
统一报告源	outputs/evaluation	scripts/generate_evaluation_report.py	本次派生输出目录
Stage 5 官方 300 当前回归	data/evaluation/stage5_mcq24_official300/contest_qa_all_results.json	scripts/evaluate_contest_qa.py	2026-07-24 当前代码质量门，300/300
Stage 5 内部困难集 holdout	outputs/evaluation/trust_challenge_100/stage5_mcq24_quality_full_report.json	scripts/evaluate_trust_challenge.py	2026-07-24 当前代码质量门，57/60，gate_passed=true