

# ReguMate 系统评测报告

生成时间: 2026- 07- 21T09:14:38.9 36039+00:00

本报告基于项目中已保存的真实实验产物重新汇总生成。报告中的数值均来自 JSON/Markdown 结果文件或本次聚合脚本的确定性重算；无法从现有文件核实的指标明确标注为“未采集”或“不可计算”。

## 1. 评测背景与目标

ReguMate 面向银行业监管制度、填报说明和统计报表的可信 RAG 问答。评测目标是验证 500 份官方附件入库、300 条官方 QA、证据引用、表格取数、拒答与 CPU/GPU 性能边界，并补充自制数据集的可复现评测入口。

## 2. 系统及技术方案概述

系统采用 FastAPI、SQLite 元数据、Qdrant 向量索引、BGE-M3 embedding、BGE reranker 和 OpenAI-compatible 大模型 API。回答链路遵循“检索到 chunk/ 表格证据才回答；依据不足则拒答”的约束，确定性表格题优先使用结构化单元格证据。

## 3. 评测环境

| 项目         | 值                                                                                 |
|------------|-----------------------------------------------------------------------------------|
| 操作系统/平台    | Windows- 11- 10.0.26200- SP0                                                      |
| Python     | 3.13.12 (tags/v3.13.12:1cbe481, Feb 3 2026, 18:22:25) [MSC v.1944 64 bit (AMD64)] |
| Git commit | 4e4a29cc7b46d7dd8d5c50a984de 3d2784b7f4bf                                         |
| 项目根目录      | D:\Agent-Project\ReguMate Agent                                                   |
| 环境变量记录     | 仅记录是否配置 API Key，不输出密钥                                                             |

## 4. 硬件与软件配置

已有性能基线文档记录：CPU 为 AMD Ryzen 9 8945HX，16 核/32 线程，内存约 34.1 GB；GPU 为 NVIDIA RTX 5070 Laptop GPU，8 GB 显存。phase1 QA 结果的资源采样峰值如下：

| 环境  | CPU 峰值  | RSS 峰值   | CUDA allocated 峰值 | CUDA reserved 峰值 | 来源                                                                                                |
|-----|---------|----------|-------------------|------------------|---------------------------------------------------------------------------------------------------|
| GPU | 434.18% | 4.22 GiB | 1.07 GiB          | 1.09 GiB         | data/ evaluation/ performanc e_ experiments/ phase1_ gpu_ full300/ contest_ qa_ all_ results.json |
| CPU | 433.94% | 0.63 GiB | 未采集               | 未采集              | data/ evaluation/ performanc e_ experiments/ phase1_ cpu_ full300/ contest_ qa_ all_ results.json |

## 5. 模型、Embedding、数据库和检索参数

| 参数                   | GPU 记录  | CPU 记录       |
|----------------------|---------|--------------|
| selected_mode        | gpu     | cpu_balanced |
| backend              | pytorch | pytorch      |
| effective_cpu_cores  | 32      | 32           |
| embedding_batch_size | 4       | 4            |
| rerank_batch_size    | 24      | 4            |
| rerank_max_length    | 1024    | 1024         |
| torch_num_threads    | 16      | 16           |

| 参数            | GPU 记录     | CPU 记录     |
|---------------|------------|------------|
| warmup_policy | background | background |

Embedding/reranker 为本地 BGE 模型；.env 中的大模型 API 影响 query planning、答案生成和高风险语义核验。本次索引完整性同时引用最终入库清单和 SQLite/Qdrant 审计：当前交付 collection 为 regumate\_chunks，Qdrant points 为 46575。

6. 数据集说明

| 数据集     | 规模         | 用途                   | 来源文件                                                         |
|---------|------------|----------------------|--------------------------------------------------------------|
| 官方附件    | 500 份      | 入库、解析、分块、索引完整性       | data/ contest_ dataset/ data set/ ; data/ contest_ staging / |
| 官方 QA   | 300 题      | 答案准确率、来源命中、分题型/难度、性能 | data/ contest_ dataset/ QA数据 .xlsx                           |
| OOD 派生题 | 30 题       | 依据不足拒答               | scripts/ evaluate_ contest_ qa.py 从官方题派生                     |
| 自制数据集   | 4 文档 / 8 题 | 功能覆盖与可复现样例           | data/ contest- data- self- made/ qa/ self_ made_ qa.json l   |

7. 500 份文档入库测试方案

500 份文档入库主结果读取 data/ evaluation/ final/ ing est\_ manifest.json，该文件记录最终入库运行的文档数、Chunk 数、表格单元格数、向量数和按扩展名/ 解析器统计。为避免只看解析性能实验导致误判，本报告另读取 outputs/ evaluation/ vector\_index\_audit.json，将冻结 SQLite 中的 document\_chunks.chunk\_id 与当前 Qdrant payload 中的 chunk\_id 做逐项一致性审计。

data/ evaluation/ performanc e\_ experiments/ index\_ parse 500.json 只作为解析/分块/SQLite persist/embedding 阶段耗时诊断，不作为主向量数来源；该诊断文件没有保存完整 Qdrant 写入结果，不代表知识库没有向量。

指标公式：入库成功率 = success / processed；平均每文档耗时与阶段耗时来自性能诊断 JSON 的原始耗时字段，并在报告中统一换算为秒。

8. 入库与向量索引结果

数据版本关系说明

为避免将不同实验产物混为同一快照，本报告明确区分官方 300 QA 评分快照、最终入库 manifest 和当前交付环境审计三类证据。三者都用于证明系统能力，但不再被表述为同一次运行的同一 collection。

| 证据/用途          | SQLite / manifest                                                                                                                               | Qdrant collection / alias                                            | 规模                                                                                                       | 与 300 QA 关系                                                           |
|----------------|-------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------|
| 官方 300 QA 评分快照 | QA 结果: data/ evaluation/ contest_ qa_ test/ 20260716_173747 / contest_ qa_ all_ results. json; SQLite 路径未在 final_contest_report 中记录             | collection=regumate_chunks; alias 未记录; build_id=dev                  | 文档=500; Qdrant points=45651; QA SHA-256=bb43588e9fb45b51a57c61516bc7ff7bd33775863b0828c74212ae69c6395a51 | 300 道官方 QA 实际使用该快照；这是 QA 准确率、来源命中率 and 响应时间的主证据                       |
| 最终入库 manifest  | data/ evaluation/ final/ ing est_ manifest.json; data_ dir =data\ evaluation\ final_ ru ntime                                                   | collection=regumate_ contest_ v3_ build; alias=regumate_ contest_ v3 | 文档=500; Chunk/ Vector=45530; C ells=133001                                                               | 用于证明 500 份官方附件可完整入库；不是 final_contest_r eport 记录的 300 QA 评分 collection |
| 当前交付环境独立审计     | SQLite=data/ evaluation/ fin al_ runtime/ app.db; 审 计文件=ou t puts/ evaluation/ vector_in dex_ audit.json; 审计时间=2026-07-21T06:17:29.052521+00:00 | collection=regumate_chunks; alias 未审计                                | 文档=500; SQLite Chunk=46575; Qdrant points=46575; Dense 维度 =1024                                          | 用于证明当前交付环境 SQLite chunk_id 与 Qdrant payload chunk_id 完全一致；属于后续交付审计证据  |

结论：官方 300 QA 使用的是 final\_contest\_report.json 记录的 regumate\_chunks 快照，Qdrant points 为 45,651；regumate\_contest\_v3\_build / regumate\_contest\_v3 是最终入库 manifest 记录的重建 collection / alias；当前交付环境审计的 regumate\_chunks 为 46,575 points。45,530、45,651、46,575  
不强行合并为同一口径。差异来自后续交付阶段对解析、分块、表格 chunk  
物化和去重规则的迭代，以及审计时间点不同；当前审计中 SQLite 与 Qdrant 的 chunk\_id 缺失数和额外数均为 0，未发现当前交付索引缺失写入 Qdrant 的证据。

汇总指标

| 指标                           | 结果                        |
|------------------------------|---------------------------|
| 文档总数                         | 500                       |
| 成功数量                         | 500                       |
| 失败数量                         | 0                         |
| 入库/解析成功率                     | 100.00%                   |
| 最终入库清单 Chunk 数               | 45530                     |
| 表格单元格数                       | 133001                    |
| 最终入库清单 Vector 数              | 45530                     |
| 最终入库 collection              | regumate_contest_v3_build |
| 最终入库 alias                   | regumate_contest_v3       |
| 审计 SQLite 文档数                | 500                       |
| 审计 SQLite Chunk 数            | 46575                     |
| 审计 Qdrant collection         | regumate_chunks           |
| 审计 Qdrant points             | 46575                     |
| Qdrant unique chunk_id       | 46575                     |
| Qdrant indexed vectors count | 93150                     |
| Dense 向量维度                   | 1024                      |
| Dense 距离度量                   | Cosine                    |
| Sparse 向量启用                  | True                      |
| SQLite/Qdrant chunk_id 一致    | 是                         |
| Qdrant 缺失 chunk_id 数         | 0                         |
| Qdrant 额外 chunk_id 数         | 0                         |

说明：最终入库清单按运行时 manifest 汇总为 45530 个向量；本次交付环境的独立审计进一步证明 SQLite 中 46575 个 chunk\_id 与 Qdrant 中 46575 个 payload chunk\_id 完全一致，missing=0、extra=0。index ed\_vectors\_count 可能大于 points，因为 collection 同时配置 dense 与 sparse 向量。

按文件格式统计：

| 格式    | 处理  | 成功  | 失败 | Chunk | Cells |
|-------|-----|-----|----|-------|-------|
| .doc  | 32  | 32  | 0  | 1365  | 0     |
| .docx | 34  | 34  | 0  | 5360  | 0     |
| .pdf  | 45  | 45  | 0  | 2802  | 0     |
| .xls  | 232 | 232 | 0  | 26752 | 87359 |
| .xlsx | 157 | 157 | 0  | 9251  | 45642 |

解析性能诊断结果：

| 指标         | 结果                                                               |
|------------|------------------------------------------------------------------|
| 诊断文件       | data/ evaluation/ performanc e_experiments/ index_parse 500.json |
| 诊断 Chunk 数 | 46577                                                            |

| 指标                   | 结果                 |
|----------------------|--------------------|
| 诊断 Qdrant 写入结果       | 未采集（未执行/未保存完整写入口径） |
| 总耗时                  | 2066.75 s          |
| 平均每文档耗时              | 4.11 s             |
| 解析阶段平均耗时             | 1.88 s             |
| 分块阶段平均耗时             | 1.69 s             |
| Embedding 阶段平均耗时     | 3.89 s             |
| SQLite chunk 持久化平均耗时 | 0.50 s             |

## 9. GPU 与 CPU 入库结果对比

当前没有同一口径的 GPU/CPU 500 文档完整向量入库耗时对比，因此不计算入库加速比；但向量完整性已由最终入库清单和 SQLite/Qdrant 一致性审计补齐。

## 10. 300 条 QA 评测方案

官方 QA 使用 scripts/ evaluate\_contest\_qa.py 调用后端 /api/qa/ask，并按 source\_type、qa\_type、difficulty 切片统计。phase1 结果额外捕获后端性能配置、资源采样、引用、context\_package 与 manifest\_evidence。

核心公式：答案准确率 = answer\_correct=True 题数 / 有效题数；来源命中率 = source\_hit=True 题数 / 有效题数；引用覆盖率 = 非拒答题 citation\_count>0 题数 / 非拒答题数；平均响应时间来自原始响应耗时字段，并在报告中 统一换算为秒。

## 11. QA 总体结果

| 指标                 | 官方最终 GPU | phase1 GPU | phase1 CPU |
|--------------------|----------|------------|------------|
| 题数                 | 300      | 300        | 300        |
| 完成题数               | 300      | 300        | 300        |
| 错误数                | 0        | 0          | 0          |
| 答案准确率              | 100.00%  | 100.00%    | 100.00%    |
| 来源命中率              | 100.00%  | 100.00%    | 100.00%    |
| 引用覆盖率              | 100.00%  | 100.00%    | 100.00%    |
| Grounding 通过率      | 100.00%  | 100.00%    | 100.00%    |
| Excel 单元格召回率       | 100.00%  | 100.00%    | 100.00%    |
| 文本证据覆盖率            | 86.00%   | 86.75%     | 86.75%     |
| 文本证据 bigram recall | 86.32%   | 86.29%     | 86.29%     |

## 12. 分题型评测结果

| 切片    | 题数  | 正确数 | 准确率     | 平均耗时   | P95    |
|-------|-----|-----|---------|--------|--------|
| 单事实检索 | 134 | 134 | 100.00% | 3.59 s | 7.03 s |
| 多事实检索 | 66  | 66  | 100.00% | 4.04 s | 6.96 s |
| 表格取数  | 34  | 34  | 100.00% | 0.40 s | 0.81 s |
| 表格比较  | 33  | 33  | 100.00% | 0.41 s | 0.68 s |
| 表格计算  | 33  | 33  | 100.00% | 0.47 s | 0.63 s |

## 13. 分难度评测结果

| 切片 | 题数  | 正确数 | 准确率     | 平均耗时   | P95    |
|----|-----|-----|---------|--------|--------|
| 中等 | 99  | 99  | 100.00% | 2.29 s | 4.17 s |
| 困难 | 99  | 99  | 100.00% | 2.85 s | 5.39 s |
| 简单 | 102 | 102 | 100.00% | 2.76 s | 4.41 s |

## 14. 检索效果评测

| 指标                          | 结果      | 说明                                                                                                                                                                      |
|-----------------------------|---------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 来源命中率                       | 100.00% | source_hit=True / 总题数                                                                                                                                                   |
| 评测口径                        | 离线候选重算  | 基于已保存候选列表，不等价于重新请求 Qdrant 的在线实验                                                                                                                                         |
| 可评估题数                       | 293     | 来源: data/ evaluation/ performance_experiments/ phase1_gpu_full300/ contest_qa_all_results.json + data/ evaluation/ performance_experiments/ evidence_manifest_seed.json |
| 可评估 aspect 数                | 469     | 仅统计 evidence manifest 中有 acceptable_chunk_ids 的 aspect                                                                                                                  |
| manifest needs_review 题数    | 14      | 需要人工复核，不作为严格 gold 直接计分                                                                                                                                                  |
| 无 acceptable chunk 题数       | 7       | 单独列出，不并入 Recall@K 分母                                                                                                                                                    |
| 无 acceptable chunk aspect 数 | 20      | 用于解释分母范围限制                                                                                                                                                              |
| Case Recall@1               | 88.05%  | 全部标准 aspect 均在 Top-1 命中                                                                                                                                                 |
| Case Recall@3               | 92.49%  | 全部标准 aspect 均在 Top-3 命中                                                                                                                                                 |
| Case Recall@5               | 98.29%  | 全部标准 aspect 均在 Top-5 命中                                                                                                                                                 |
| Aspect Recall@1             | 92.54%  | 标准 aspect 粒度 Top-1 命中                                                                                                                                                   |
| Aspect Recall@3             | 95.31%  | 标准 aspect 粒度 Top-3 命中                                                                                                                                                   |
| Aspect Recall@5             | 98.93%  | 标准 aspect 粒度 Top-5 命中                                                                                                                                                   |
| 最终上下文 Case Recall           | 100.00% | acceptable chunk 进入最终 prompt 上下文                                                                                                                                        |

检索 TopK 指标由 scripts/ evaluate\_retrieval\_from\_results.py 基于已保存 context\_package.retrieval\_summary.aspect\_retrievals[] .retrieved\_chunks 和 evidence\_manifest\_seed.json 离线重算；manifest 中 14 题为 needs\_review，其中 7 题没有 acceptable chunk，单独列入明细，不并入 Recall@K 分母。scripts/ evaluate\_online\_retrieval\_recall.py 已提供直接调用 /api/qa/retrieve 的在线复现实验入口，但必须后端绑定非空官方 SQLite 与同一 Qdrant collection 后运行，不能用空知识库冒烟结果作为正式指标。

## 15. 证据引用与可追溯性评测

| 指标                             | 结果      |
|--------------------------------|---------|
| 引用覆盖率                          | 100.00% |
| Grounding 通过率                  | 100.00% |
| Reviewed citation accuracy     | 100.00% |
| Reviewed citation completeness | 100.00% |
| 无效引用案例数                        | 0       |
| 缺少行内引用案例数                      | 0       |
| Unsupported entity 案例数         | 0       |

## 16. 表格取数能力评测

| 指标           | 结果      |
|--------------|---------|
| Excel 题数     | 100     |
| Excel 准确率    | 100.00% |
| Excel 单元格召回率 | 100.00% |

| 指标      | 结果      |
|---------|---------|
| 表格取数准确率 | 100.00% |
| 表格比较准确率 | 100.00% |
| 表格计算准确率 | 100.00% |

## 17. 拒答与幻觉抑制评测

| 指标          | GPU OOD | CPU OOD |
|-------------|---------|---------|
| 题数          | 30      | 30      |
| 拒答准确率       | 100.00% | 100.00% |
| 答案准确率       | 100.00% | 100.00% |
| 关键实体错误率代理指标 | 0.00%   | 0.00%   |

注意：关键实体错误率代理指标不等价于经人工逐条标注的真实幻觉率。现有数据没有人工逐条幻觉标注；报告使用 key\_entity\_error\_rate 作为代理指标，并同时报告 OOD 拒答准确率。

## 18. 自制数据集评测

| 项目         | 结果                                                                     |
|------------|------------------------------------------------------------------------|
| 数据集名称      | contest-data-self-made                                                 |
| 文档数        | 4                                                                      |
| QA 题数      | 8                                                                      |
| 题型分布       | 业务流程题:1；依据不足拒答题:1；制度事实题:1；条款 口径题:1；条款阈值题:1；表格取数题:1；表格计算题: 1；跨文件场景判断题:1 |
| 难度分布       | 中等:2；简单:5；越界/依据不足:1                                                    |
| API 实测模式   | api                                                                    |
| 完成题数       | 8                                                                      |
| API 答案准确率  | 100.00%                                                                |
| 来源文件名命中率   | 100.00%                                                                |
| 引用覆盖率      | 100.00%                                                                |
| 依据不足拒答正确数  | 1/1                                                                    |
| 平均响应时间     | 8.21 s                                                                 |
| P95 响应时间   | 27.00 s                                                                |
| 跨文件场景判断题结果 | 通过                                                                     |
| 数据合规       | 无敏感客户数据：True；无真实银行交易数据：True                                            |

自制数据集标准答案由自制监管制度、填报说明和 CSV 报表中的显式事实人工编写。本轮已经连接运行中后端完成 8 道题在线实测，制度事实、流程、表格取数、表格计算、跨文件场景判断和依据不足拒答均通过。该数据集规模较小，定位为补充功能覆盖与复现样例，不包装为官方 300 题同等口径的核心指标。

## 19. 性能与响应时间评测

| 环境  | 平均     | P50    | P90     | P95     | 最大      |
|-----|--------|--------|---------|---------|---------|
| GPU | 2.63 s | 2.75 s | 4.18 s  | 4.73 s  | 47.86 s |
| CPU | 8.85 s | 9.59 s | 18.44 s | 20.09 s | 28.10 s |

## 20. GPU 与 CPU 问答性能对比

| 指标     | GPU     | CPU     | 对比              |
|--------|---------|---------|-----------------|
| 平均响应时间 | 2.63 s  | 8.85 s  | CPU/GPU = 3.36x |
| P95    | 4.73 s  | 20.09 s |                 |
| 准确率    | 100.00% | 100.00% | 一致              |

## 21. 典型正确案例

### 正确回答且证据准确

问题：根据 Excel 附件《2023年10月人身险公司经营情况表》（工作表：人 身保险公司（月度）），“原保险保费收入”在“本年累计/ 截至当期”口径下的 数值是多少？

标准答案：A

系统答案：答案为 31739.18。依据表格证据，核验值为 31739.18。[1]

引用来源：145\_ 2023年10月人身险公司经营情况表\_ 2023年10月人身险公司经营情况表.xlsx

评分结果：answer\_correct=True, source\_hit=True, citation\_count=1

错误类型：无

原始运行：phase1\_gpu\_full300 / Q001

## 22. 典型错误案例

本次汇总的官方 300 题 phase1 GPU/CPU 与 OOD 结果中未发现 answer\_correct=False 的错误案例，outputs/evaluation/error\_cases.jsonl 为空。用户要求列出的“答案正确但引用不准确、检索正确但生成错误、检索未命中、表格行列或期间识别错误、新旧文件版本混淆、错误拒答、发生幻觉”等类别，在现有可核验结果中未出现，不能构造示例。

## 23. 错误原因分类

| 错误类型               | 数量 | 说明                      |
|--------------------|----|-------------------------|
| 答案错误               | 0  | 来自 qa_details.jsonl     |
| 请求/程序错误            | 0  | 来自 error 字段             |
| 引用不准确              | 0  | 来自 grounding_validation |
| 缺少行内引用             | 0  | 来自 grounding_validation |
| Unsupported entity | 0  | 来自 grounding_validation |

## 24. 当前系统已知问题

500 文档完整 GPU/CPU 向量入库耗时对比未找到同一口径结果，因此不报告入库加速比；向量完整性已通过最终入库 manifest 与 SQLite/Qdrant chunk\_id 审计补证。

当前 Recall@1/3/5 结果来自已保存候选列表的离线重算，不等价于完整 300 题在线 Qdrant 检索实验；在线脚本已补充，但需要在同一官方 SQLite/collection 快照上执行后才可形成正式在线指标。

自制数据集已经完成在线 API 实测且 8 题全部通过，但规模较小，只能证明补充样例覆盖，不能替代官方 300 题与 OOD 指标。

幻觉率没有人工逐条标注，当前只报告 key\_entity\_error\_rate 对应的关键实体错误率代理指标和 grounding 结果。

## 25. 评测局限性

官方 300 题能覆盖 Excel、Word、PDF、表格取数/ 比较/ 计算和 文本证据，但仍是固定题集；OOD 为派生 30 题，不代表所有越界问题。资源采样来自后端内部采样，不等价于整机监控。外部 LLM API 网络耗时未独立拆分。

## 26. 改进方向

在入库脚本中保存 parse、chunk、embedding、Qdrant upsert、SQLite persist 的完整阶段耗时、upsert 成功/失败数和资源峰值。

在同一冻结 collection 快照上补跑 scripts/ evaluate\_online\_retrieval\_recall.py，保存每题 Top1/3/5、初始召回与 rerank 后排名变化。

扩充自制数据集的表格期间、跨文件场景和依据不足样本，并保留后续回归结果 JSON/JSONL。

增加人工抽样复核文件，区分答案错误、引用错误、检索错误和幻觉。

## 27. 结论

可核验的官方最终 GPU 报告显示 300/300 完成、答案准确率 100.00%、来源命中率 100.00%，该 QA 快照记录 collection=regumate\_chunks、points=45651。phase1 GPU/CPU 300 题均为 100.00% 准确率；GPU 平均响应 2.63 s，CPU 平均响应 8.85 s。500 文档最终入库清单为 500/500 成功、45530 个向量；当前交付环境独立审计证明 SQLite 46575 个 chunk\_id 与 Qdrant 46575 个 points 完全匹配，missing=0、extra=0。

## 28. 复现方法

从已有结果生成统一评测产物和报告：

```
python scripts\generate_evaluation_report.py --output-dir outputs\evaluation --output docs\系统评测报告.md
```

只汇总入库结果：

```
python scripts\evaluate_ingestion.py --result data\evaluation\final\ingest_manifest.json --output-dir outputs\evaluation
```

审计 SQLite chunk 与 Qdrant payload/vector 一致性：

```
$env:PYTHONIOENCODING='utf-8'
python scripts\audit_vector_index.py --db data\evaluation\final_runtime\app.db --ingest-manifest data\evaluation\final\ingest_manifest.json --qdrant-url http://127.0.0.1:6333 --collection regumate_chunks --output outputs\evaluation\vector_index_audit.json
```

从已有 QA 结果生成 QA 指标：

```
python scripts\evaluate_qa.py --from-existing --output-dir outputs\evaluation
```

连接运行中后端重新执行官方 QA：

```
python scripts\evaluate_qa.py --run-backend-eval --dataset data\contest_dataset\QA数据.xlsx --base-url http://127.0.0.1:8000 --device cuda --split all --output-dir outputs\evaluation
```

自制数据集复现：

```
powershell -NoProfile -ExecutionPolicy Bypass -File .\scripts\run_self_made_evaluation.ps1
```



```
python scripts\ evaluate_ custom_ d ataset.py --output-dir outputs\evaluation
```

CPU/GPU QA 对比:

```
python scripts\compare_cpu_gpu.py --output-dir outputs\evaluation
```

在线检索 Recall 复现实验入口:

```
python scripts\ evaluate_ online_ r etrieval_ recall.py --base-url http://127.0.0.1:8000 --output-dir outputs\
evaluation\ online_ retrieval --timeout 240 --resume
```

运行该在线检索脚本前，必须确认 /api/health/ready 绑定的是官方 500 文档 SQLite 与同一 Qdrant collection；空库或不同 collection 只可作为环境诊断，不得计入正式 Recall。

29. 实验结果文件索引

| 实验                 | 原始结果文件                                                                                                | 执行/生成脚本                                       | 说明                                            |
|--------------------|-------------------------------------------------------------------------------------------------------|-----------------------------------------------|-----------------------------------------------|
| 官方最终 300 QA        | data/ evaluation/ contest_ q a_ test/ 20260716_ 173747/ c ontest_ qa_ all_ results. jso n             | scripts/ build_ contest_ rep ort.py           | 官方最终口径                                        |
| phase1 GPU 300 QA  | data/ evaluation/ performanc e_ experiments/ phase1_ gpu_ full300/ contest_ qa_ all_ results.json     | scripts/ evaluate_ contest_ qa.py             | 完整引用/context/performance 结果                   |
| phase1 CPU 300 QA  | data/ evaluation/ performanc e_ experiments/ phase1_ cpu_ full300/ contest_ qa_ all_ results.json     | scripts/ evaluate_ contest_ qa.py             | CPU 问答性能                                      |
| GPU OOD 30         | data/ evaluation/ performanc e_ baseline/ gpu_ 20260718_ 182304/ ood/ contest_ qa_ oo d_ results.json | scripts/ evaluate_ contest_ qa.py --split ood | 拒答评测                                          |
| 最终入库 manifest 500  | data/ evaluation/ final/ ing est_ manifest.json                                                       | scripts/ ingest_ contest_ da taset.py         | 500 文档成功数、Chunk、Cells、Vector                  |
| SQLite/Qdrant 向量审计 | outputs/ evaluation/ vector_ index_ audit.json                                                        | scripts/ audit_ vector_ inde x.py             | SQLite chunk_id 与 Qdrant payload chunk_id 一致性 |
| CPU 解析/分块性能诊断 500  | data/ evaluation/ performanc e_ experiments/ index_ parse 500.json                                    | scripts/ ingest_ contest_ da taset.py         | 解析/分块/SQLite persist/embeddin g 阶段耗时；不作为向量数来源 |
| 自制数据集              | data/ contest- data- self- m ade/ manifest.json                                                       | scripts/ generate_ self_ mad e_ artifacts.py  | 离线设计与 PDF/MD/JSON 产物                          |
| 统一报告源              | outputs/evaluation                                                                                    | scripts/ generate_ evaluatio n_ report.py     | 本次派生输出目录                                      |

缺失或不可核实数据

GPU 500 文档入库性能结果：已找到 CPU 解析/分块基线与 QA GPU/CPU 结果，但未找到同口径的 GPU 500 文档完整入库结果。已检查：data/ evaluation/ perfor mance\_ experiments/ ; data/ evaluation/ performanc e\_ baseline/ ; docs/ evaluation/ performanc e\_ baseline\_ 20260718.md。建议命令：使用 GPU 模式启动后执行 contest 数据入库脚本，并保留 JSON/日志输出。