第五届中国研究生金融科技创新大赛
The 5th CHINA POSTGRADUATE FINTECH INNOVATION COMPETITION

指导单位：
教育部学位管理与研究生教育司、中国人民银行科技司

主办单位：
中国学位与研究生教育学会

学术指导单位：
全国金融专业学位研究生教育指导委员会

特别支持：
江苏省金融学会

承办单位：
南京大学、南京市建邺区人民政府

协办单位：
江苏省数字金融重点实验室、江苏省金科数字与科技金融研究院

组委会秘书处：
清华大学五道口金融学院

CPIPC 中国研究生创新实践系列大赛
CPIPC 金融科技创新大赛
第五届中国研究生金融科技创新大赛
THE 5TH CHINA POSTGRADUATE FINTECH INNOVATION COMPETITION

ReguMate 可信RAG问答系统

V0rtex 团队

队长：王博震　　队员：李思、刘晨阳

目录

01 背景与问题
02 解决方案
03 技术亮点
04 评测结果
05 性能与稳定性
06 落地价值

01

背景与问题

背景与问题：银行真实业务场景的监管问答之痛

信贷审批、风险分类、资本管理、消保投诉、反洗钱、支付结算、普惠金融、监管报送等场景均需快速查询制度依据与指标口径

资料分散、格式多样

监管文件分散于金融监管总局、人民银行、政府网站等多渠道，Word / PDF / Excel / 附件并存，更新频繁、版本差异明显

人工查询易出错

易漏查、误用旧规、条款定位不准、表格指标口径混淆；固定报表与自助分析难以满足跨文件、跨版本、跨表格的监管问答需求

业务要求准确可追溯

业务判断要求“准确可追溯”，但现有查询流程分散、格式复杂、人工检索难以稳定保证可信性

命题四大技术卡点

- 多源异构文档解析难：版式差异大，常规切分难以保留标题层级、条款编号、表头结构、单位与时间维度；
- 检索精度与证据定位难：仅关键词召回易同名文件、新旧版本混淆，无法稳定返回最小充分证据；
- 跨文件跨模态推理难：需同时理解制度正文与统计报表，通用模型易跳过依据生成不可核验答案；
- 金融合规表达要求高：须区分“应当/可以/不得/原则上”，数字、日期、机构、文号细微错误影响业务判断。

02

解决方案

总体思路：以可信 RAG 为核心的端到端业务链路

构建 “输入 → 结构化处理 → 检索推理 → 可信校验 → 可溯源输出 → 审计评测” 全链路，打造监管知识问答系统

输入 | 结构化处理 | 检索推理 | 可信校验 | 可溯源输出 | 审计评测

设计原则

1. 确定性优先

表格取数、计算、拒答边界全部程序化，不依赖大语言模型 LLM 猜测

2. 证据闭环

答案必须引用条款/段落/单元格证据，事实校验失败自动修复或拒答

3. 通用能力

均为语言与结构层面通用改进，不绑定具体题目，评测集做回归门禁

4. 可溯源

入库、评测、评分全部脚本化，manifest 记录 doc_id 与 SHA-256 溯源

目标：形成 “问得准、找得到、答得清、可追溯、可溯源” 的系统方案

系统架构：FastAPI + React 前后端分离，双存储双引擎

Docker 一键镜像部署，CPU/GPU 双配置，全链路留存文件哈希与条款编号溯源凭证

前端 React + TypeScript + Vite —— 问答页 / 文档管理页 / 审计页（流式答案、引用来源展示、系统状态）

查询规划 QueryPlanner

多视角子查询

HyDE 补检索

混合检索层

稠密/稀疏/关键词

表格单元检索 • BGE 重排

生成层 LLM+证据受限

prompt 组装→生成→修复→降级

CRAG-lite 分级路由

确定性表格链路

取数 / 计算 / 比较

毫秒级返回

事实/引用校验

数字/日期/机构/文号

确定性校验

拒答边界

依据不足/库外/冲突

结构化拒答不补写

Qdrant 向量索引	SQLite 双存储	BGE-M3 + BGE-reranker-v2-m3	DeepSeek API	LibreOffice + pymupdf4llm
45,530 条	46,551 chunk / 133,001 单元格	本地嵌入与重排	生成 / 规划 / 校验	PDF / Word / Excel 解析

任务一：多源异构文档解析与结构化索引

500 份监管文件 100% 入库（0 失败、0 降级），解析成功率 100%

多格式解析管线

- .pdf：pymupdf4llm 版式感知解析文本段落
- .doc / .docx：python-docx + LibreOffice 结构抽取
- .xls / .xlsx：解析为带行/列标签、坐标、数值、单位、公式的单元格
- Word/表格元数据：段落、表格、章节结构与条款号元数据

结构化索引（解决“常规切分丢结构”）

- 条款级元数据：chunk 挂载 section_number、parent_section、前后邻接，监管“第X条”结构得以保留
- 表格单元级索引：Excel 附件不按文本切分，133,001 个结构化单元格支持按指标/期间/机构精确召回与确定性取数
- 双索引并行：SQLite（元数据+单元格）与 Qdrant（向量）双引擎

500	45,530	46,551	133,001	100%
监管文件全量入库	Qdrant 向量索引	chunk 元数据	结构化表格单元格	解析成功率

全链路可溯源： manifest 记录 doc_id / 标题 / SHA-256 / 解析结果，入库、评测、评分全脚本化，可一键重建与评测环境一致的 500 份文件知识库

任务二：多路混合检索与跨文档推理引擎

稠密 + 稀疏 + BM25 + 元数据过滤四路召回，RRF 融合排序

混合检索 规划查询

BGE-M3 稠密/稀疏 + BM25 关键词 + 元数据过滤四路召回，RRF 融合；支持文件名、主题、条款编号、指标名称、期间维度过滤；复杂问题自动生成多视角子查询分别检索、合并证据；

HyDE 缺口补检索

未覆盖 aspect 由 LLM 生成“假设条款”参与补检，缓解监管术语问法与文档措辞不匹配

条款引用多跳图

解析“本办法第X条”引用关系，跨章节定位被引条款，补齐跨条款依据，支撑跨文档深度推理

条款级索引 定义定位

“X 是指”类定义问题先定位定义条款，再取前后邻接 chunk，解决定义句被切碎、同概念条款错位

CRAG-lite 分级路由

生成前判断证据覆盖度：正确→直接生成；缺失→定向补检索（禁止性规定、兜底条款、列表枚举模式）；仍不足→结构化拒答

确定性表格链路

按指标+期间+机构维度程序化取数，算术仅限安全算子、变量必须来自证据，LLM 不参与数值计算——表格取数、计算实测 100%

答案可验证性与幻觉抑制：三道防线的可信屏障

从生成受限 → 事实校验 → 拒答兜底，杜绝“语言流畅但依据错误”的答案进入业务流程

01 证据受限生成

- 提示词强制：仅使用知识片段原文组句、逐条引用 [n] 标注来源
- 每条 citations 携带 doc_id / chunk_id / 文件名 / 章节 / 摘录
- 证据粒度：条款级 / 段落级 / 表格单元级三种粒度返回
- 证据不足必须拒答

02 事实校验 Grounding

- 关键数字、比例、日期、机构名称、文号与证据一致性核验
- 引用标签按词面重叠重定向
- LLM 自由发挥内容在校验前清理
- 校验失败最多一次自动修复，仍失败则拒答

03 拒答边界

- 依据不足、资料冲突、问题含糊、知识库外问题一律结构化拒答
- 拒答时给出原因，不补写、不猜测
- 自命题 200 题中 40 道依据不足题拒答率100%

引用返回率 100% | 关键实体错误率 2.4%（≤5%） | 证据引用命中率 91%+（≥90%） | 拒答率 100%（≥80%）

03

技术亮点

技术亮点：相比现有技术的六项突破

① 监管条款“保持结构”

按“第X条—章节—上下级标题—前后邻接”建立条款级索引，先定位核心条款再补齐上下文，降低条款错位与断章取义风险

② 检索“会自检、会补证”

CRAG-lite 生成前诊断覆盖缺口，禁止性规定、兜底条款、列表枚举定向补搜；HyDE 生成假设条款补检，而非让模型绕过证据直接作答

③ 复杂问题沿证据链推理

复杂问题自动拆解为多检索方面；解析“本办法第X条”引用关系，沿章节邻接与引用边补齐跨条款依据，增强跨文件证据完整性

④ 表格问答脱离大模型估算

13.3 万单元格结构化索引，取数/求和/差值/比例/最值由安全算子程序化执行，答案同步返回计算式与单元格坐标——表格问答实测 100%

⑤ 答案“可信防火墙”

“结论—引用—原文”闭环校验，自动检查数字/日期/机构/文号/引用标签；失败依次执行引用修复、证据受限再生成或结构化拒答

⑥ 双层评测验证明工程能力

官方 300 题 + 自建 200 题冻结评测集，确定性评分逐事实比对；45,530 向量与 133,001 单元格索引全量构建，多项指标全部达标

04

测评结果

评测结果：赛题五项量化指标全部达标

官方 300 题（选择题）+ 自命题 200 题（开放问答，金标逐事实确定性评分）双评测体系

指标	赛题要求	实测结果
官方 300 题准确率	—	300/300（100%），0 错误，多次回归一致
制度事实类准确率	≥85%	89.3%（CPU）/ 85.7%（GPU）
表格取数类准确率	≥80%	100%（40/40）；官方 300 中取数 34/34、计算 33/33
证据引用命中率	≥90%	91.3%（CPU）/ 91.9%（GPU），引用返回率 100%
关键数字/日期/机构/文号错误率	≤5%	2.4%（按事实计）
拒答/澄清率	≥80%	100%（40/40 依据不足题全部结构化拒答）

自命题 200 题总准确率：183/200 = 91.5%（CPU）　180/200 = 90.0%（GPU），两轮 0 运行错误

实验迭代：RAGAS 三层归因驱动的四阶段升级

200 题联合评测曾卡在 87%，分层归因确认瓶颈在检索层而非生成层：≥15/26 失败题为证据拿不到或拿错

问题归因	证据拿不到：定义条款被挤出 top-k、同概念附件错位；多文档题只检索到一份；校验机制可靠
阶段一	条款级索引 + 定义条款定位 + 附件/章节限定加权 → 定义类 26/30→29/30，错位题恢复
阶段二	CRAG-lite 分级路由 + 列表完整性补搜 + 引用修复 → 拒答边界修复
阶段三	并发 503 修复 + 延迟优化 → 40 题并发 0 错误，rerank 耗时减半（17.5s→8.9s）
阶段四	HyDE 覆盖缺口补检索 + 条款引用多跳 → 拒答/0 分题恢复识片段

合计：自命题 200 题 87% → 91.5%（CPU），官方 300 题全程保持 300/300、0 错误

05

性能与稳定性

性能与稳定性工程：从可用到可靠

两轮各 500 题（300+200）CPU/GPU 全量测试 0 运行错误

单轮问答实测（串行，RTX 5070 Laptop / Ryzen 9 8945HX）

评测集	CPU 平均	GPU 平均
官方 300 题（选择题）	7.03 s	0.54 s
自命题 200 题（开放问答）	28.4 s	17.9 s

- 选择题 P50 仅 0.22－0.26s：大部分走确定性表格链路，毫秒级返回
- 开放题延迟由 LLM API 主导（约 10－12s/题）：GPU 将本地检索+重排从 ~15s 压到 ~3s，P50 提速 2.1 倍
- 长尾为 LLM API 偶发慢响应：非本地计算瓶颈

稳定性问题 → 修复

- 并发 503（修复前 31 个）：模型获取移出推理锁 + API 瞬态重试 → 4 workers × 40 题并发 0 错误
- SQLite 无法打开数据库：WAL 移入 named volume + 回退 DELETE 模式 + busy timeout
- rerank 慢（~1.3s/对）：输入 24→12、batch 16，rerank 17.5s→8.9s
- LLM 空输出：max_tokens 900→3000，流式/非流式交替重试

入库性能：500 文件全量解析+切分+持久化 2,066.75 秒（约 34 分钟，一次性离线流程，不影响问答延迟）

06

落地价值

落地价值

ReguMate —— 从比赛方案走向银行真实业务的可信监管问答能力

业务价值

问答即合规

- 覆盖核心场景：信贷审批、风险分类、资本管理、消保投诉、反洗钱、支付结算、普惠金融、监管报送
- 回答可审计：条款级 / 单元格级证据一键追溯，满足监管可解释硬性要求
- 降低合规风险：杜绝误用旧规、条款错引、数字失真，守住合规底线

技术价值

方案可复制

- 通用架构：解析—检索—生成—校验全链路均为语言/结构层通用设计，不绑定具体题目
- 快速适配：标准化文档处理流程，可快速迁移至多类金融合规文档场景
- 轻量部署：Docker 一键镜像部署，CPU / GPU 双配置，门槛低、易推广

运营价值

能力可持续

- 新文档快速接入：幂等入库脚本，新监管文件发布即可增量构建索引
- 质量可度量：评测集作为回归门禁，每次升级可量化验证、能力不退化
- 成本可控：本地嵌入+重排与确定性链路承担大部分查询，API 调用最小化

让每一份监管答案都“有依据、可核验、可审计”，为银行合规数字化转型提供可信基础设施

谢谢观看！

V0rtex 团队

队长：王博震

队员：李思、刘晨阳