

ReguMate 可信 RAG 问答系统 —— 测试报告

赛题： 面向银行业监管制度与统计报表的可信 RAG 问答（南京银行，揭榜挂帅赛道）

1. 测试概述

1.1 测试目的

围绕赛题量化指标与系统能力指标，对系统进行正确率、性能、证据可信能力与 稳定性四个维度的全量测试：

1. 知识库构建（500 份监管文件入库）的耗时与成功率；
2. 官方 300 题（选择题）正确率与处理时间；
3. 自命题 200 题（开放问答）正确率、证据引用命中率、拒答率、实体错误率与 处理时间（CPU / GPU 两种环境）；
4. 并发稳定性。

1.2 我们自制了 200 题开放问答题

官方 300 题为**选择题**（选项比对即可判定），主要验证检索与识别能力，但**无法完全展示系统的真实能力**：选择题不需要系统自主组织答案、无法考察答案表述中的数字/日期/机构/文号准确性、证据引用是否真实命中来源文件、依据不足时是否诚实拒答等开放问答关键能力。

因此，我们依据银行业真实业务场景（信贷审批、风险分类、资本管理、消保投诉、反洗钱、支付结算、普惠金融、监管报送等）自命题 **200 道开放问答题**，覆盖八类题型——制度定义、规则/适用范围、金额阈值、名单类、表格取数、表格计算、跨文件场景判断、依据不足拒答——并编写金标（标准答案）与**确定性评分器**（无 LLM 判定，金标结论与答案逐条比对），用于测试系统的开放问答能力。

1.3 测试结论摘要

指标	赛题要求	实测结果
官方 300 题（选择题）准确率	—	300/300 (100%) , 0 错误
制度事实类准确率（自命题 200 题）	≥85%	89.3% (CPU)
表格取数类准确率	≥80%	100% (40/40)
证据引用命中率	≥90%	91.3% (CPU) / 91.9% (GPU)
关键数字/日期/机构/文号错误率	≤5%	2.4%
拒答/澄清率（依据不足题）	≥80%	100% (40/40)
自命题 200 题总准确率	—	183/200 = 91.5% (CPU)

2. 测试环境

项目	配置
CPU	AMD Ryzen 9 8945HX (16 核/32 线程) , 内存约 34 GB
GPU	NVIDIA GeForce RTX 5070 Laptop, 8 GB 显存 (CUDA 可用)
运行方式	Docker 容器 <code>regumate/app:contest-v3</code> (build_id <code>regumate-agent-small</code>) , torch 2.11.0+cu128
模型	BGE-M3 (embedding, 本地) + BGE-reranker-v2-m3 (重排, 本地) + DeepSeek API (deepseek-v4-flash, 生成/规划/校验)
知识库	官方 500 份监管制度与统计附件 (doc 32 / docx 34 / pdf 45 / xls 232 / xlsx 157)
向量索引	Qdrant, 45,530 条向量 (稠密+稀疏混合检索)
结构化索引	SQLite, 46,551 chunk + 133,001 表格单元格 (坐标/行/列标签/单位/数值)
CPU 模式	容器无 CUDA 时按 <code>MODEL_DEVICE=cuda</code> 请求自动回退 <code>cpu_balanced</code> (16 线程)
GPU 模式	<code>--gpus all</code> 启动, <code>selected_device=cuda</code> , <code>performance_mode=gpu</code>

官方 300 题与自命题 200 题在 CPU、GPU 两种环境下各完整跑测一轮，串行执行、0 运行错误，保证逐题延迟测量纯净。

3. 知识库构建与入库性能

3.1 入库成功率与规模

项目	结果
文件总数	500 (.doc 32 / .docx 34 / .pdf 45 / .xls 232 / .xlsx 157)
解析成功 / 失败 / 降级	500 / 0 / 0 (100%)
文本与表格 chunk	46,551 条 (条款号/章节/前后邻接元数据)
结构化表格单元格	133,001 个
向量索引	45,530 条 (Qdrant)

3.2 入库耗时 (CPU, 2026-07-18 隔离解析基线)

项目	耗时
500 文件全量解析+切分+持久化总耗时	2,066.75 秒 (约 34 分 27 秒)
单文档平均 / P50 / P95 / 最大	4.11 / 1.74 / 19.27 / 104.32 秒
文件解析 (聚合平均)	1.88 秒/文档
Chunk 构建 (聚合平均)	1.69 秒/文档 (含 BGE-M3 语义切分推理)
SQLite/单元格持久化 (聚合平均)	0.50 秒/文档
最慢样本	长 PDF (104.32 秒) 、长 XLS 表单 (76.87 秒)

分类型：XLS 232 份 2.40 s/份、XLSX 157 份 1.22 s/份、PDF 45 份 17.08 s/份、DOC 32 份 6.16 s/份、DOCX 34 份 10.03 s/份。

入库为一次性离线流程（幂等脚本 `scripts/ingest_contest_dataset.py`），上线后不影响单轮问答延迟。完整重建命令见包内 `data/evaluation/文档解析结果说明.md`。

4. 官方 300 题测试 (选择题)

官方题集：`data/contest_dataset/QA数据.xlsx`（300 题，Excel/Word/PDF 各 100，覆盖表格取数、表格计算、表格比较、单/多事实检索等题型，含证据与来源字段）。

4.1 正确率

300/300 = 100%，0 运行错误——本次 CPU、GPU 两轮实测均为 300/300，与开发期间 10+ 次回归结果一致（每次生产改动后回归，始终 300/300）。

4.2 处理时间（单轮问答，串行）

环境	平均	P50	P95	最大
CPU（2026-08-05 实测）	7.03 s	0.26 s	32.2 s	64.2 s
GPU（2026-08-05 实测）	0.54 s	0.22 s	3.51 s	8.66 s

选择题大部分为确定性表格链路（Excel 类 P50 ~0.2 s，CPU/GPU 几乎无差）；文本类含 LLM 生成，GPU 平均提速约 13 倍（7.03 → 0.54 s）。

5. 自命题 200 题测试（开放问答）

题集：旧批 100 题（去锚100题）+ 新批 100 题（去锚100题B），八类题型：制度定义、规则/适用范围、金额阈值、名单类、表格取数、表格计算、跨文件场景判断、依据不足拒答。金标与确定性评分器随包交付（data/evaluation/自命题200题评测集/）。

5.1 正确率

批次	CPU（2026-08-05 最终验收）	GPU（2026-08-05 实测）
旧批 100 题	90/100	88/100
新批 100 题	93/100	92/100
合计	183/200 = 91.5%	180/200 = 90.0%

两轮均 0 运行错误。GPU 与 CPU 差 3 题，处于同代码重复运行已记录的 LLM 生成波动区间（±1–3 题），非设备差异；表格类 40/40、拒答 40/40 两轮完全一致。

5.2 分类型准确率（合计 200 题）

题型	CPU	GPU
表格取数	20/20（100%）	20/20（100%）

题型	CPU	GPU
表格计算	20/20 (100%)	20/20 (100%)
拒答 (依据不足)	40/40 (100%)	40/40 (100%)
制度定义	29/30	27/30
规则/适用范围	32/40	35/40
金额阈值	25/26	22/26
名单类	14/16	12/16
跨文件场景判断	3/8	4/8

5.3 证据与可信指标

指标	赛题要求	CPU 实测	GPU 实测
证据引用命中率 (金标来源文件全部命中引用)	≥90%	91.3% (旧 85.0%/新 97.5%)	91.9% (旧 87.5%/新 96.2%)
引用返回率 (回答必带引用)	—	100%	100%
关键数字/日期/机构/文号错误率 (按事实计)	≤5%	2.4% (旧 0%/新 4.2%)	— (同评分口径)
拒答/澄清率	≥80%	100% (40/40)	100% (40/40)

5.4 处理时间 (单轮问答，串行)

批次	CPU 平均 / P50 / 最大	GPU 平均 / P50 / 最大
旧批 100 题	25.5 / 28.2 / 88.5 s	17.1 / 13.6 / 99.5 s
新批 100 题	31.3 / 31.8 / 134.6 s	18.7 / 14.5 / 168.8 s
合计 200 题	28.4 / 29.8 / 134.6 s	17.9 / 14.1 / 168.8 s

开放题延迟由 LLM API 生成 (约 10–12 s/题) 主导; GPU 将本地检索+重排从 ~15 s 压到 ~3 s, 平均提速 1.6 倍、P50 提速 2.1 倍。长尾 max 为 LLM API 偶发慢响应 (CPU/GPU 均存在), 非本地计算瓶颈。拒答类与表格类确定性链路 毫秒级返回 (~10–70 ms)。

6. 并发与稳定性

项目	结果
4 workers × 40 题 并发	0 错误 (修复前 31 个 503; 已通过锁外取模型、锁等待不耗预算、API 瞬态重试修复)

项目	结果
官方 300 并发/串行回归	多次 300/300、0 错误
本次 CPU/GPU 全量测试	两轮各 500 题 (300+200) 0 运行错误
后端单元测试	588 passed
反硬编码审计	0 findings

7. 结论

- 1. 官方 300 题选择题 **300/300 (100%)** , 0 错误;
 - 2. 自命题 200 题开放问答 **183/200 (91.5%, CPU) / 180/200 (90.0%, GPU)** , 0 运行错误——官方选择题之外, 系统在开放问答 (自主组织答案、证据引用、诚实拒答) 上同样具备高准确率与可信性;
 - 3. 赛题五项量化指标全部达标: 制度事实类 89.3%、表格取数类 100%、证据引用 命中率 91.3–91.9%、实体错误率 2.4%、拒答率 100%;
 - 4. 性能: 官方 300 题 GPU 平均 0.54 s; 开放 200 题 GPU 平均 17.9 s (CPU 28.4 s) , 满足比赛平台交互要求 (确定性表格题毫秒级返回) ;
 - 5. 知识库 500 份文件 100% 入库 (约 34 分钟一次性流程) , 证据支持条款级/ 段落级/表格单元级三种粒度返回。
-

附录：测试产物与复现

产物	位置
官方 300 计时 (CPU)	evaluation/系统测试结果/官方300题/CPU_20260805/official_300_results.json
官方 300 计时 (GPU)	evaluation/系统测试结果/官方300题/GPU_20260805/official_300_results.json
自命题 200 题 (CPU)	evaluation/系统测试结果/自命题200题/CPU_最终验收20260805/ (评分 90+93)
自命题 200 题 (GPU)	evaluation/系统测试结果/自命题200题/GPU_20260805/ (评分 88+92)
入库性能基线	性能实验/indexing-baseline.md
复现命令	代码包 README.md 「系统测试」 章节

产物	位置
题集/金标/评分器	data/自命题200题评测集/ (包内)