

# 面向银行业监管制度与统计报表的可信 RAG 问答系统 —— 技术文档

**参赛单位：**揭榜挂帅赛道三号赛题（南京银行） **版本：**v2.0（2026-08-05，四阶段升级完成版）

---

## 1. 赛题理解与总体思路

### 1.1 命题背景

银行业经营管理高度依赖监管制度、业务规程、统计报表与内部操作文件。信贷审批、风险分类、资本管理、消保投诉、反洗钱、支付结算、普惠金融与监管报送等场景都需要快速查询制度依据与指标口径。资料分散于金融监管总局、人民银行、政府网站等多个渠道，格式包含 Word、PDF、Excel 与网页附件，更新频繁、版本差异明显，人工查询易漏查、误用旧规、条款定位不准、表格指标口径混淆。


### 1.2 技术挑战（命题列明的四个卡点）

- 多源异构文档解析难：**监管原文 PDF/Word 版式差异大，统计附件以 xls/xlsx 为主，常规切分难以保留标题层级、条款编号、表头结构、单位与时间维度；
- 检索精度与证据定位难：**问题依赖具体条款、金额阈值、期限、适用对象、例外情形与附件指标，仅关键词召回易出现同名文件、旧版新规混淆，无法稳定返回最小充分证据；
- 跨文件与跨模态推理难：**部分问题需同时理解制度正文与统计报表，通用问答模型容易跳过检索依据，产生看似合理但不可核验的答案；
- 金融合规表达要求高：**答案需区分“应当、可以、不得、原则上”等规范强度，并准确呈现金额、比例、日期、机构名称与文号，细微数字或主体错误可能影响业务判断。

1.3 总体设计原则

- **确定性优先**：表格取数、表格计算、拒答边界等可程序化环节全部走确定性 链路，不依赖 LLM 猜测；LLM 仅用于文本答案组织与语义理解；
- **证据闭环**：答案必须引用证据（条款级/段落级/表格单元级），返回前经 事实校验（数字、日期、机构、文号、引用标签），校验失败自动修复或拒答， 证据不足一律拒答而非补写；
- **通用能力**：所有优化均为语言/结构特征层面的通用改进，不绑定具体题目 与文档，用评测集做回归门禁；
- **可复现**：知识库构建、评测跑测、评分全部脚本化，manifest 记录文件 溯源信息（doc\_id、SHA-256、路径）。

2. 系统架构



2.1 技术选型

| 组件        | 选型                                                        | 用途                                          |
|-----------|-----------------------------------------------------------|---------------------------------------------|
| 后端框架      | FastAPI + Uvicorn                                         | API 服务（分层：api/schemas/models/services/core） |
| 向量数据库     | Qdrant 1.18                                               | 稠密/稀疏向量混合检索                                 |
| 关系存储      | SQLite（WAL）                                               | 文档、chunk、表格单元元数据与结构化索引                      |
| Embedding | BGE-M3（本地）                                                | 稠密向量 + 稀疏向量                                 |
| 重排        | BGE-reranker-v2-m3（本地）                                    | 交叉编码器精排                                     |
| 生成/规划     | DeepSeek API（deepseek-v4-flash）                           | 查询规划、答案生成、语义校验                              |
| 文档解析      | python-docx / pymupdf4llm / xlrd / openpyxl / LibreOffice | Word/PDF/Excel 多格式解析                        |
| 前端        | React + TypeScript + Vite                                 | Web 客户端                                     |

| 组件 | 选型                              | 用途         |
|----|---------------------------------|------------|
| 部署 | Docker Compose<br>(CPU/GPU 双配置) | 一键部署与可复现环境 |

### 3. 知识库构建（任务一：文档解析与索引流程）

#### 3.1 多格式解析

| 格式           | 解析器                            | 结构化产出                          |
|--------------|--------------------------------|--------------------------------|
| .doc         | LibreOffice 转换 + 结构抽取          | 段落、标题层级、条款号元数据                 |
| .docx        | python-docx                    | 段落、表格、章节结构                     |
| .pdf         | pymupdf4llm                    | 版式感知的文本段落                      |
| .xls / .xlsx | xlrd / openpyxl (+LibreOffice) | sheet → 单元格（行/列标签、坐标、数值、单位、公式） |

#### 3.2 结构化索引（解决”常规切分丢结构”）

- **条款级元数据**：每个 chunk 挂载 section\_number、parent\_section、前后邻接 chunk、标题层级，监管”第X条”结构得以保留；
- **表格单元级索引**：Excel 附件不按文本切分，而是将每个 sheet 解析为 133,001 个带坐标、行/列标签、单位、数值的结构化单元格，支持按指标名称、期间维度、机构维度精确召回与确定性取数；
- **双索引**：SQLite（元数据 + 单元格查询）与 Qdrant（向量检索）并行，向量索引 45,530 条。

#### 3.3 入库规模与溯源

- **500 份文件**（doc 32 / docx 34 / pdf 45 / xls 232 / xlsx 157），**解析成功率 100%**（0 失败、0 降级）；
- 每文件在 manifest 中记录 doc\_id、标题、本地路径、文件大小、SHA-256、解析结果（chunk/cell 数）等溯源信息；
- **全部流程脚本化**：prepare\_contest\_data.ps1 → ingest\_contest\_dataset.py → 校验 evaluate\_ingestion.py，可一键重建与评测一致的 500 份文件知识库。

## 4. 检索层（任务二：可溯源问答生成能力之检索）

### 4.1 混合检索

综合稠密向量（BGE-M3）+ 稀疏向量 + 关键词（BM25 类）+ 元数据过滤 四路召回，RRF 融合排序；支持按文件名称、监管主题、业务领域、条款编号、指标名称、期间维度过滤。

### 4.2 查询规划（Query Planner）

对复杂问题生成多视角子查询（aspect），分别检索后合并证据；规划超时 12 秒，失败自动降级为单查询。

### 4.3 条款级索引与定义条款定位（阶段一）

- 定义型问题（“X 是如何定义的/所称 X 是指”）先定位”所称X/ X是指”条款，再取该条款所在 chunk 及前后邻接，解决定义句被切碎、同概念条款错位（如”内部评级法” ↔ “权重法”附件混淆）问题；
- 检索候选按附件匹配度与章界限定词加分（`_retrieval_fit_score`）。

### 4.4 CRAG-lite 分级路由（阶段二）

生成前判断”证据是否覆盖问题要点”：- 证据正确 → 直接生成；- 证据缺失/模糊 → 定向补检索（文档内词面补搜、禁止性规定模式补搜、兜底条款通道、“哪些/包括”列表枚举条款补充），仍不足则结构化拒答；- 生成后校验失败 → 证据受限二次生成（仅使用知识片段原文组句），再失败走 extractive 摘录或拒答，杜绝自由发挥。

### 4.5 HyDE 覆盖缺口补检索 + 监管文档结构图（阶段四）

- **HyDE**：规划查询全部无果的未覆盖 aspect，由 LLM 生成”假设条款”参与检索，缓解监管术语问法与文档措辞不匹配（每请求 ≤2 aspect、1 次 LLM 调用）；
- **文档结构图条款引用多跳**：解析”本办法第X条”引用关系，跨章节定位被引条款，解决跨文档/跨条款多跳推理（X 组跨文档题）。

4.6 确定性表格链路

表格取数/计算/比较走程序化链路：按指标名 + 期间 + 机构维度从单元格索引取数，算术仅限安全算子且变量必须来自证据，LLM 不参与数值计算——官方 300 与自命题 200 题中**表格取数、表格计算全部 100% 通过**。

5. 生成与可信控制（答案可验证性、幻觉抑制）

5.1 证据受限生成

提示词强制” 仅使用知识片段原文组句、逐条引用 [n] 标注来源、证据不足必须拒答”；每条回答的 citations 携带 doc\_id、chunk\_id、文件名、章节与摘录，支持条款级/段落级/表格单元级三种粒度证据返回。

5.2 事实校验（Grounding）

返回前对答案做确定性校验：关键数字、比例、日期、机构名称、文号必须与证据一致；引用标签按词面重叠重定向；LLM 自由发挥的标注在校验前清理。校验失败最多自动修复，仍失败则拒答。

5.3 拒答边界

依据不足、资料冲突、问题含糊、知识库外问题一律结构化拒答并给出原因——自命题 200 题中 40 道依据不足/数据缺失题**拒答率 100%**。

6. 性能与稳定性工程

| 问题                                    | 根因                    | 修复                                                  |
|---------------------------------------|-----------------------|-----------------------------------------------------|
| 并发 503（4 workers 31 个）                | 模型锁串行化 + LLM 竞争       | 模型获取移出推理锁、锁等待不消耗预算、API 层瞬态重试一次 → <b>40 题并发 0 错误</b> |
| SQLite “unable to open database file” | WAL 在 bind mount 上不可靠 | 移入 named volume + 回退 DELETE 模式 + busy_timeout       |

| 问题      | 根因                  | 修复                                                         |
|---------|---------------------|------------------------------------------------------------|
| 开放题延迟高  | CPU rerank 逐对 ~1.3s | rerank 输入 24→12、batch 16、planner/生成超时收紧（rerank 17.5s→8.9s） |
| LLM 空输出 | max_tokens 被思考耗尽    | 900→3000、attempts 4 交替流式/非流式重试                             |

7. 实验设计与量化指标

7.1 评测体系

| 评测集                        | 题量  | 评分方式             | 用途                                     |
|----------------------------|-----|------------------|----------------------------------------|
| 官方 300 题（选择题）              | 300 | 选项比对（确定性）        | AGENTS.md 硬门禁，每次生产改动后回归                |
| 官方 300 开放问答（judge 口径）      | 300 | LLM judge + 人工复核 | 开放式能力基线（84.7%）                         |
| 自命题 200 题（旧批 100 + 新批 100） | 200 | 确定性评分器（金标逐事实比对）  | 八类题型细粒度回归：定义/规则/阈值/名单/表格取数/表格计算/跨文档/拒答 |

自命题评分器为确定性程序：归一化 bigram recall  $\geq 0.55$  且关键实体（数字/日期/文号/《文件名》）全命中、无语义极性冲突即判事实通过；证据 引用命中率按”金标要求来源文件全部出现在引用中”计算；逐题输出 passed/failure\_category/facts\_met/source\_evidence\_met/latency\_ms。

7.2 量化指标实测（2026-08-05，0 运行错误）

| 指标                  | 赛题要求        | 实测                          |
|---------------------|-------------|-----------------------------|
| 官方 300 题准确率         | —           | 300/300 (100%)，0 错误（多次回归一致） |
| 制度事实类准确率（自命题 200 题： | $\geq 85\%$ | 89.3% (CPU) / 85.7% (GPU)   |

| 指标               | 赛题要求 | 实测                                          |
|------------------|------|---------------------------------------------|
| 定义+规则+阈值+名单)     |      |                                             |
| 表格取数类准确率         | ≥80% | 100% (40/40); 官方 300 中取数 34/34、计算 33/33     |
| 证据引用命中率          | ≥90% | 91.3% (CPU) / 91.9% (GPU)                   |
| 关键数字/日期/机构/文号错误率 | ≤5%  | 2.4% (按事实计)                                 |
| 拒答/澄清率           | ≥80% | 100% (40/40)                                |
| 自命题 200 题总准确率    | —    | 183/200 (91.5%, CPU) / 180/200 (90.0%, GPU) |

7.3 性能实测（单轮问答，串行，RTX 5070 Laptop / Ryzen 9 8945HX)

| 评测集             | CPU 平均 / P50 / P95 / 最大      | GPU 平均 / P50 / P95 / 最大      |
|-----------------|------------------------------|------------------------------|
| 官方 300（选择题）     | 7.03 / 0.26 / 32.2 / 64.2 s  | 0.54 / 0.22 / 3.51 / 8.66 s  |
| 自命题 200 题（开放问答） | 28.4 / 29.8 / 72.0 / 134.6 s | 17.9 / 14.1 / 58.0 / 168.8 s |

开放题延迟由 LLM API 生成（约 10–12 s/题）主导，GPU 将本地检索+重排从 ~15 s 压到 ~3 s（平均提速 1.6 倍、P50 提速 2.1 倍）；长尾为 LLM API 偶发 慢响应（CPU/GPU 均有）。选择题大部分走确定性表格链路（P50 ~0.2 s）。

7.4 工程验证

- 后端单元测试 588 passed;
- 反硬编码审计 0 findings（逐批审计产物随包交付）;
- 官方 300 在四阶段升级期间 6+ 次回归均 300/300、0 错误;
- 4 workers 并发 40 题 0 错误（修复前 31 个 503）。

## 8. 迭代与失败归因（RAGAS 三层）

200 题联合评测曾卡在 87%，分层归因（context\_recall / context\_precision / faithfulness）确认**瓶颈在检索层而非生成层**：≥15/26 题失败为证据拿不到 或拿错（定义条款被挤出 top-k、同概念附件错位、多文档题只检索到一份），而校验机制可靠（无幻觉，是证据错了）。据此实施四阶段升级：

| 阶段 | 内容                              | 效果                                                |
|----|---------------------------------|---------------------------------------------------|
| 一  | 条款级索引 + 定义条款定位 + 附件/章节限定加权      | 定义类 26/30→29/30，错位题恢复                             |
| 二  | CRAG-lite 分级路由 + 列表完整性补搜 + 引用修复 | 拒答边界修复，B2-R10 0/4→4/5                             |
| 三  | 并发 503 修复 + 延迟优化                | 40 题并发 0 错误，rerank 减半                             |
| 四  | HyDE 覆盖缺口补检索 + 条款引用多跳           | BW-D12/B2-L01 从拒答/0/5 恢复                          |
| 合计 | —                               | <b>200 题 87% → 91.5% (CPU)</b> ，官方 300 保持 300/300 |

## 9. 创新点总结

- 1. **条款级索引 + 定义条款定位**：监管文档按”第X条”结构索引，定义型问题 先定位定义条款再取上下文，解决条款错位与定义句切碎；
- 2. **CRAG-lite 分级路由**：生成前”证据-问题”相关性判断，证据缺失自动定向补检索（禁止性规定、兜底条款、列表枚举等模式），而非直接生成；
- 3. **HyDE 覆盖缺口补检索 + 监管文档结构图**：假设条款检索 + “本办法第X条”引用图多跳，解决跨文档/跨条款推理；
- 4. **确定性表格链路**：133,001 单元格结构化索引 + 程序化取数/计算，表格类题目 100% 准确且毫秒级返回；
- 5. **证据闭环校验**：数字/日期/机构/文号/引用标签确定性校验 + 证据受限 二次生成 + 结构化拒答，实体错误率 2.4%、拒答率 100%、证据引用命中率 91%+。



## 10. 复现说明与已知限制

### 10.1 复现

见代码提交包 README.md 与 data/自命题200题评测集/README.md：一键构建镜像 → 一键入库 500 文件 → 官方 300 回归 → 自命题 200 题跑测评分。知识库重建后与评测环境一致（manifest SHA-256 可校验）。

### 10.2 已知限制（如实说明）

- **LLM 生成波动**：同代码重复运行准确率波动  $\pm 1-3$  题（文本生成题）；
- **跨文档题仍偏弱**：8 题中 3-4 题通过（金标要求多文件引用时生成层 对比结论 偶有缺漏）；
- **开放题延迟长尾**：LLM API 偶发慢响应（最大  $\sim 170$  s），本地计算非瓶颈；
- **官方 300 开放问答（judge 口径）84.7%**：低于选择题 100%，属开放式 生成口径，选择题（官方硬门禁）与自命题确定性评分均已达标。