

ReguMate 系统评测报告

生成时间: 2026- 07- 21T07:13:43.2 00988+00:00

本报告基于项目中已保存的真实实验产物重新汇总生成。报告中的数值均来自 JSON/Markdown 结果文件或本次聚合脚本的确定性重算；无法从现有文件核实的指标明确标注为“未采集”或“不可计算”。

1. 评测背景与目标

ReguMate 面向银行业监管制度、填报说明和统计报表的可信 RAG 问答。评测目标是验证 500 份官方附件入库、300 条官方 QA、证据引用、表格取数、拒答与 CPU/GPU 性能边界，并补充自制数据集的可复现评测入口。

2. 系统及技术方案概述

系统采用 FastAPI、SQLite 元数据、Qdrant 向量索引、BGE-M3 embedding、BGE reranker 和 OpenAI-compatible 大模型 API。回答链路遵循“检索到 chunk/ 表格证据才回答；依据不足则拒答”的约束，确定性表格题优先使用结构化单元格证据。

3. 评测环境

项目	值
操作系统/平台	Windows- 11- 10.0.26200- SP0
Python	3.13.12 (tags/v3.13.12:1cbe481, Feb 3 2026, 18:22:25) [MSC v.1944 64 bit (AMD64)]
Git commit	4e4a29cc7b46d7dd8d5c50a984de 3d2784b7f4bf
项目根目录	D:\Agent-Project\ReguMate Agent
环境变量记录	仅记录是否配置 API Key，不输出密钥

4. 硬件与软件配置

已有性能基线文档记录：CPU 为 AMD Ryzen 9 8945HX，16 核/32 线程，内存约 34.1 GB；GPU 为 NVIDIA RTX 5070 Laptop GPU，8 GB 显存。phase1 QA 结果的资源采样峰值如下：

环境	CPU 峰值	RSS 峰值	CUDA allocated 峰值	CUDA reserved 峰值	来源
GPU	434.18%	4.22 GiB	1.07 GiB	1.09 GiB	data/ evaluation/ performanc e_ experiments/ phase1_ gpu_ full300/ contest_ qa_ all_ results.json
CPU	433.94%	0.63 GiB	未采集	未采集	data/ evaluation/ performanc e_ experiments/ phase1_ cpu_ full300/ contest_ qa_ all_ results.json

5. 模型、Embedding、数据库和检索参数

参数	GPU 记录	CPU 记录
selected_mode	gpu	cpu_balanced
backend	pytorch	pytorch
effective_cpu_cores	32	32
embedding_batch_size	4	4
rerank_batch_size	24	4
rerank_max_length	1024	1024
torch_num_threads	16	16

参数	GPU 记录	CPU 记录
warmup_policy	background	background

Embedding/reranker 为本地 BGE 模型；.env 中的大模型 API 影响 query planning、答案生成和高风险语义核验。本次索引完整性同时引用最终入库清单和 SQLite/Qdrant 审计：当前交付 collection 为 regumate_chunks，Qdrant points 为 46575。

6. 数据集说明

数据集	规模	用途	来源文件
官方附件	500 份	入库、解析、分块、索引完整性	data/ contest_ dataset/ data set/ ; data/ contest_ staging /
官方 QA	300 题	答案准确率、来源命中、分题型/难度、性能	data/ contest_ dataset/ QA数据 .xlsx
OOD 派生题	30 题	依据不足拒答	scripts/ evaluate_ contest_ qa.py 从官方题派生
自制数据集	4 文档 / 8 题	功能覆盖与可复现样例	data/ contest- data- self- made/ qa/ self_ made_ qa.json l

7. 500 份文档入库测试方案

500 份文档入库主结果读取 data/ evaluation/ final/ ing est_ manifest.json，该文件记录最终入库运行的文档数、Chunk 数、表格单元格数、向量数和按扩展名/ 解析器统计。为避免只看解析性能实验导致误判，本报告另读取 outputs/ evaluation/ vector_index_audit.json，将冻结 SQLite 中的 document_chunks.chunk_id 与当前 Qdrant payload 中的 chunk_id 做逐项一致性审计。

data/ evaluation/ performanc e_ experiments/ index_ parse 500.json 只作为解析/分块/SQLite persist/embedding 阶段耗时诊断，不作为主向量数来源；该诊断文件没有保存完整 Qdrant 写入结果，不代表知识库没有向量。

指标公式：入库成功率 = success / processed；平均每文档耗时与阶段耗时来自性能诊断 JSON 的原始耗时字段，并在报告中统一换算为秒。

8. 入库与向量索引结果

数据版本关系说明

为避免将不同实验产物混为同一快照，本报告明确区分官方 300 QA 评分快照、最终入库 manifest 和当前交付环境审计三类证据。三者都用于证明系统能力，但不再被表述为同一次运行的同一 collection。

证据/用途	SQLite / manifest	Qdrant collection / alias	规模	与 300 QA 关系
官方 300 QA 评分快照	QA 结果: data/ evaluation/ contest_ qa_test/ 20260716_173747 / contest_ qa_all_results. json; SQLite 路径未在 final_contest_report 中记录	collection=regumate_chunks; alias 未记录; build_id=dev	文档=500; Qdrant points=45651; QA SHA-256=bb43588e9fb45b51a57c61516bc7ff7bd33775863b0828c74212ae69c6395a51	300 道官方 QA 实际使用该快照；这是 QA 准确率、来源命中率 and 响应时间的主证据
最终入库 manifest	data/ evaluation/ final/ ing est_ manifest.json; data_dir =data\ evaluation\ final_ runtime	collection=regumate_contest_v3_build; alias=regumate_contest_v3	文档=500; Chunk/ Vector=45530; Cells=133001	用于证明 500 份官方附件可完整入库；不是 final_contest_report 记录的 300 QA 评分 collection
当前交付环境独立审计	SQLite=data/ evaluation/ fin al_ runtime/ app.db; 审计文件=outputs/ evaluation/ vector_in dex_audit.json; 审计时间=2026-07-21T06:17:29.052521+00:00	collection=regumate_chunks; alias 未审计	文档=500; SQLite Chunk=46575; Qdrant points=46575; Dense 维度=1024	用于证明当前交付环境 SQLite chunk_id 与 Qdrant payload chunk_id 完全一致；属于后续交付审计证据

结论：官方 300 QA 使用的是 final_contest_report.json 记录的 regumate_chunks 快照，Qdrant points 为 45,651；regumate_contest_v3_build / regumate_contest_v3 是最终入库 manifest 记录的重建 collection / alias；当前交付环境审计的 regumate_chunks 为 46,575 points。45,530、45,651、46,575
不强行合并为同一口径。差异来自后续交付阶段对解析、分块、表格 chunk
物化和去重规则的迭代，以及审计时间点不同；当前审计中 SQLite 与 Qdrant 的 chunk_id 缺失数和额外数均为 0，未发现当前交付索引缺失写入 Qdrant 的证据。

汇总指标

指标	结果
文档总数	500
成功数量	500
失败数量	0
入库/解析成功率	100.00%
最终入库清单 Chunk 数	45530
表格单元格数	133001
最终入库清单 Vector 数	45530
最终入库 collection	regumate_contest_v3_build
最终入库 alias	regumate_contest_v3
审计 SQLite 文档数	500
审计 SQLite Chunk 数	46575
审计 Qdrant collection	regumate_chunks
审计 Qdrant points	46575
Qdrant unique chunk_id	46575
Qdrant indexed vectors count	93150
Dense 向量维度	1024
Dense 距离度量	Cosine
Sparse 向量启用	True
SQLite/Qdrant chunk_id 一致	是
Qdrant 缺失 chunk_id 数	0
Qdrant 额外 chunk_id 数	0

说明：最终入库清单按运行时 manifest 汇总为 45530 个向量；本次交付环境的独立审计进一步证明 SQLite 中 46575 个 chunk_id 与 Qdrant 中 46575 个 payload chunk_id 完全一致，missing=0、extra=0。index ed_vectors_count 可能大于 points，因为 collection 同时配置 dense 与 sparse 向量。

按文件格式统计：

格式	处理	成功	失败	Chunk	Cells
.doc	32	32	0	1365	0
.docx	34	34	0	5360	0
.pdf	45	45	0	2802	0
.xls	232	232	0	26752	87359
.xlsx	157	157	0	9251	45642

解析性能诊断结果：

指标	结果
诊断文件	data/ evaluation/ performanc e_experiments/ index_parse 500.json
诊断 Chunk 数	46577

指标	结果
诊断 Qdrant 写入结果	未采集（未执行/未保存完整写入口径）
总耗时	2066.75 s
平均每文档耗时	4.11 s
解析阶段平均耗时	1.88 s
分块阶段平均耗时	1.69 s
Embedding 阶段平均耗时	3.89 s
SQLite chunk 持久化平均耗时	0.50 s

9. GPU 与 CPU 入库结果对比

当前没有同一口径的 GPU/CPU 500 文档完整向量入库耗时对比，因此不计算入库加速比；但向量完整性已由最终入库清单和 SQLite/Qdrant 一致性审计补齐。

10. 300 条 QA 评测方案

官方 QA 使用 scripts/ evaluate_contest_qa.py 调用后端 /api/qa/ask，并按 source_type、qa_type、difficulty 切片统计。phase1 结果额外捕获后端性能配置、资源采样、引用、context_package 与 manifest_evidence。

核心公式：答案准确率 = answer_correct=True 题数 / 有效题数；来源命中率 = source_hit=True 题数 / 有效题数；引用覆盖率 = 非拒答题 citation_count>0 题数 / 非拒答题数；平均响应时间来自原始响应耗时字段，并在报告中 统一换算为秒。

11. QA 总体结果

指标	官方最终 GPU	phase1 GPU	phase1 CPU
题数	300	300	300
完成题数	300	300	300
错误数	0	0	0
答案准确率	100.00%	100.00%	100.00%
来源命中率	100.00%	100.00%	100.00%
引用覆盖率	100.00%	100.00%	100.00%
Grounding 通过率	100.00%	100.00%	100.00%
Excel 单元格召回率	100.00%	100.00%	100.00%
文本证据覆盖率	86.00%	86.75%	86.75%
文本证据 bigram recall	86.32%	86.29%	86.29%

12. 分题型评测结果

切片	题数	正确数	准确率	平均耗时	P95
单事实检索	134	134	100.00%	3.59 s	7.03 s
多事实检索	66	66	100.00%	4.04 s	6.96 s
表格取数	34	34	100.00%	0.40 s	0.81 s
表格比较	33	33	100.00%	0.41 s	0.68 s
表格计算	33	33	100.00%	0.47 s	0.63 s

13. 分难度评测结果

切片	题数	正确数	准确率	平均耗时	P95
中等	99	99	100.00%	2.29 s	4.17 s
困难	99	99	100.00%	2.85 s	5.39 s
简单	102	102	100.00%	2.76 s	4.41 s

14. 检索效果评测

指标	结果	说明
来源命中率	100.00%	source_hit=True / 总题数
评测口径	离线候选重算	基于已保存候选列表，不等价于重新请求 Qdrant 的在线实验
可评估题数	293	来源: data/ evaluation/ performance_experiments/ phase1_gpu_full300/ contest_qa_all_results.json + data/ evaluation/ performance_experiments/ evidence_manifest_seed.json
可评估 aspect 数	469	仅统计 evidence manifest 中有 acceptable_chunk_ids 的 aspect
manifest needs_review 题数	14	需要人工复核，不作为严格 gold 直接计分
无 acceptable chunk 题数	7	单独列出，不并入 Recall@K 分母
无 acceptable chunk aspect 数	20	用于解释分母范围限制
Case Recall@1	88.05%	全部标准 aspect 均在 Top-1 命中
Case Recall@3	92.49%	全部标准 aspect 均在 Top-3 命中
Case Recall@5	98.29%	全部标准 aspect 均在 Top-5 命中
Aspect Recall@1	92.54%	标准 aspect 粒度 Top-1 命中
Aspect Recall@3	95.31%	标准 aspect 粒度 Top-3 命中
Aspect Recall@5	98.93%	标准 aspect 粒度 Top-5 命中
最终上下文 Case Recall	100.00%	acceptable chunk 进入最终 prompt 上下文

检索 TopK 指标由 scripts/ evaluate_retrieval_from_results.py 基于已保存 context_package.retrieval_summary.aspect_retrievals[] .retrieved_chunks 和 evidence_manifest_seed.json 离线重算；manifest 中 14 题为 needs_review，其中 7 题没有 acceptable chunk，单独列入明细，不并入 Recall@K 分母。scripts/ evaluate_online_retrieval_recall.py 已提供直接调用 /api/qa/retrieve 的在线复现实验入口，但必须在后端绑定非空官方 SQLite 与同一 Qdrant collection 后运行，不能用空知识库冒烟结果作为正式指标。

15. 证据引用与可追溯性评测

指标	结果
引用覆盖率	100.00%
Grounding 通过率	100.00%
Reviewed citation accuracy	100.00%
Reviewed citation completeness	100.00%
无效引用案例数	0
缺少行内引用案例数	0
Unsupported entity 案例数	0

16. 表格取数能力评测

指标	结果
Excel 题数	100
Excel 准确率	100.00%
Excel 单元格召回率	100.00%

指标	结果
表格取数准确率	100.00%
表格比较准确率	100.00%
表格计算准确率	100.00%

17. 拒答与幻觉抑制评测

指标	GPU OOD	CPU OOD
题数	30	30
拒答准确率	100.00%	100.00%
答案准确率	100.00%	100.00%
关键实体错误率代理指标	0.00%	0.00%

注意：关键实体错误率代理指标不等价于经人工逐条标注的真实幻觉率。现有数据没有人工逐条幻觉标注；报告使用 key_entity_error_rate 作为代理指标，并同时报告 OOD 拒答准确率。

18. 自制数据集评测

项目	结果
数据集名称	contest-data-self-made
文档数	4
QA 题数	8
题型分布	业务流程题:1；依据不足拒答题:1；制度事实题:1；条款 口径题:1；条款阈值题:1；表格取数题:1；表格计算题: 1；跨文件场景判断题:1
难度分布	中等:2；简单:5；越界/依据不足:1
API 实测模式	api
完成题数	8
API 答案准确率	25.00%
来源文件名称命中率	25.00%
引用覆盖率	57.14%
依据不足拒答正确数	0/1
平均响应时间	4.41 s
P95 响应时间	14.83 s
跨文件场景判断题结果	未通过
数据合规	无敏感客户数据：True；无真实银行交易数据：True

自制数据集标准答案由自制监管制度、填报说明和 CSV 报表中的显式事实人工编写。本轮已经连接运行中后端完成 8 道题在线实测，结果作为诊断指标纳入报告：制度事实和流程类问题可正确引用制度材料，但表格期间识别、跨文件表格计算和依据不足拒答仍暴露缺陷，因此不把自制数据集结果包装为官方 300 题同等口径的核心指标。

19. 性能与响应时间评测

环境	平均	P50	P90	P95	最大
GPU	2.63 s	2.75 s	4.18 s	4.73 s	47.86 s
CPU	8.85 s	9.59 s	18.44 s	20.09 s	28.10 s

20. GPU 与 CPU 问答性能对比

指标	GPU	CPU	对比
平均响应时间	2.63 s	8.85 s	CPU/GPU = 3.36x
P95	4.73 s	20.09 s	
准确率	100.00%	100.00%	一致

21. 典型正确案例

正确回答且证据准确

问题：根据 Excel 附件《2023年10月人身险公司经营情况表》（工作表：人 身保险公司（月度）），“原保险保费收入”在“本年累计/ 截至当期”口径下的 数值是多少？

标准答案：A

系统答案：答案为 31739.18。依据表格证据，核验值为 31739.18。[1]

引用来源：145_ 2023年10月人身险公司经营情况表_ 2023年10月人身险公司经营情况表.xlsx

评分结果：answer_correct=True, source_hit=True, citation_count=1

错误类型：无

原始运行：phase1_gpu_full300 / Q001

22. 典型错误案例

本次汇总的官方 300 题 phase1 GPU/CPU 与 OOD 结果中未发现 answer_correct=False 的错误案例，outputs/evaluation/error_cases.jsonl 为空。用户要求列出的“答案正确但引用不准确、检索正确但生成错误、检索未命中、表格行列或期间识别错误、新旧文件版本混淆、错误拒答、发生幻觉”等类别，在现有可核验结果中未出现，不能构造示例。

23. 错误原因分类

错误类型	数量	说明
答案错误	0	来自 qa_details.jsonl
请求/程序错误	0	来自 error 字段
引用不准确	0	来自 grounding_validation
缺少行内引用	0	来自 grounding_validation
Unsupported entity	0	来自 grounding_validation

24. 当前系统已知问题

500 文档完整 GPU/CPU 向量入库耗时对比未找到同一口径结果，因此不报告入库加速比；向量完整性已通过最终入库 manifest 与 SQLite/Qdrant chunk_id 审计补证。

当前 Recall@1/3/5 结果来自已保存候选列表的离线重算，不等价于完整 300 题在线 Qdrant 检索实验；在线脚本已补充，但需要在同一官方 SQLite/collection 快照上执行后才可形成正式在线指标。

自制数据集已经完成在线 API 实测，但 8 题规模较小，且当前结果显示表格期间识别、跨文件表格计算和依据不足拒答仍需优化。

幻觉率没有人工逐条标注，当前只报告 key_entity_error_rate 对应的关键实体错误率代理指标和 grounding 结果。

25. 评测局限性

官方 300 题能覆盖 Excel、Word、PDF、表格取数/ 比较/ 计算和 文本证据，但仍是固定题集；OOD 为派生 30 题，不代表所有越界问题。资源采样来自后端内部采样，不等价于整机监控。外部 LLM API 网络耗时未独立拆分。

26. 改进方向

在入库脚本中保存 parse、chunk、embedding、Qdrant upsert、SQLite persist 的完整阶段耗时、upsert 成功/失败数和资源峰值。

在同一冻结 collection 快照上补跑 scripts/ evaluate_online_retrieval_recall.py，保存每题 Top1/3/5、初始召回与 rerank 后排名变化。

针对自制数据集暴露的问题优化表格期间识别、表格检索路由和 依据不足拒答策略，并保留后续回归结果 JSON/JSONL。

增加人工抽样复核文件，区分答案错误、引用错误、检索错误和 幻觉。

27. 结论

可核验的官方最终 GPU 报告显示 300/300 完成、答案准确率 100.00%、来源命中率 100.00%，该 QA 快照记录 collection=regumate_chunks、points=45651。phase1 GPU/CPU 300 题均为 100.00% 准确率；GPU 平均响应 2.63 s，CPU 平均响应 8.85 s。500 文档最终入库清单为 500/500 成功、45530 个向量；当前交付环境独立审计证明 SQLite 46575 个 chunk_id 与 Qdrant 46575 个 points 完全匹配，missing=0、extra=0。

28. 复现方法

从已有结果生成统一评测产物和报告：

```
python scripts\generate_evaluation_report.py --output-dir outputs\evaluation --output docs\系统评测报告.md
```

只汇总入库结果：

```
python scripts\evaluate_ingestion.py --result data\evaluation\final\ingest_manifest.json --output-dir outputs\evaluation
```

审计 SQLite chunk 与 Qdrant payload/vector 一致性：

```
$env:PYTHONIOENCODING='utf-8'
python scripts\audit_vector_index.py --db data\evaluation\final_runtime\app.db --ingest-manifest data\evaluation\final\ingest_manifest.json --qdrant-url http://127.0.0.1:6333 --collection regumate_chunks --output outputs\evaluation\vector_index_audit.json
```

从已有 QA 结果生成 QA 指标：

```
python scripts\evaluate_qa.py --from-existing --output-dir outputs\evaluation
```

连接运行中后端重新执行官方 QA：

```
python scripts\evaluate_qa.py --run-backend-eval --dataset data\contest_dataset\QA数据.xlsx --base-url http://127.0.0.1:8000 --device cuda --split all --output-dir outputs\evaluation
```

自制数据集复现：

```
powershell -NoProfile -ExecutionPolicy Bypass -File .\ scripts\ run_ self_ made_ evaluation.ps1
python scripts\ evaluate_ custom_ d ataset.py --output-dir outputs\evaluation
```

CPU/GPU QA 对比:

```
python scripts\compare_cpu_gpu.py --output-dir outputs\evaluation
```

在线检索 Recall 复现实验入口:

```
python scripts\ evaluate_ online_ r etrieval_ recall.py --base-url http://127.0.0.1:8000 --output-dir outputs\
evaluation\ online_ retrieval --timeout 240 --resume
```

运行该在线检索脚本前，必须确认 /api/health/ready 绑定的是官方 500 文档 SQLite 与同一 Qdrant collection；空库或不同 collection 只可作为环境诊断，不得计入正式 Recall。

29. 实验结果文件索引

实验	原始结果文件	执行/生成脚本	说明
官方最终 300 QA	data/ evaluation/ contest_ q a_ test/ 20260716_ 173747/ c ontest_ qa_ all_ results. js o n	scripts/ build_ contest_ rep ort.py	官方最终口径
phase1 GPU 300 QA	data/ evaluation/ performanc e_ experiments/ phase1_ gpu_ full300/ contest_ qa_ all_ results. json	scripts/ evaluate_ contest_ qa.py	完整引用/context/performance 结果
phase1 CPU 300 QA	data/ evaluation/ performanc e_ experiments/ phase1_ cpu_ full300/ contest_ qa_ all_ results. json	scripts/ evaluate_ contest_ qa.py	CPU 问答性能
GPU OOD 30	data/ evaluation/ performanc e_ baseline/ gpu_ 20260718_ 182304/ ood/ contest_ qa_ oo d_ results. json	scripts/ evaluate_ contest_ qa.py --split ood	拒答评测
最终入库 manifest 500	data/ evaluation/ final/ ing est_ manifest. json	scripts/ ingest_ contest_ da taset.py	500 文档成功数、Chunk、Cells、Vector
SQLite/Qdrant 向量审计	outputs/ evaluation/ vector_ index_ audit. json	scripts/ audit_ vector_ inde x.py	SQLite chunk_id 与 Qdrant payload chunk_id 一致性
CPU 解析/分块性能诊断 500	data/ evaluation/ performanc e_ experiments/ index_ parse 500. json	scripts/ ingest_ contest_ da taset.py	解析/分块/SQLite persist/embeddin g 阶段耗时； 不作为向量数来源
自制数据集	data/ contest- data- self- m ade/ manifest. json	scripts/ generate_ self_ mad e_ artifacts.py	离线设计与 PDF/MD/JSON 产物
统一报告源	outputs/evaluation	scripts/ generate_ evaluatio n_ report.py	本次派生输出目录

缺失或不可核实数据

GPU 500 文档入库性能结果：已找到 CPU 解析/分块基线与 QA GPU/CPU 结果，但未找到同口径的 GPU 500 文档完整入库结果。 已检查： data/ evaluation/ perfor mance_ experiments/ ; data/ evaluation/ performanc e_ baseline/ ; docs/ evaluation/ performanc e_ baseline_ 20260718.md。建议命令：使用 GPU 模式启动后执行 contest 数据入库脚本，并保留 JSON/日志输出。