

ReguMate 系统评测报告

生成时间：2026-07-21T05:11:45.221502+00:00

本报告基于项目中已保存的真实实验产物重新汇总生成。报告中的数值均来自 JSON/Markdown 结果文件或本次聚合脚本的确定性重算；无法从现有文件核实的指标明确标注为“未采集”或“不可计算”。

1. 评测背景与目标

ReguMate 面向银行业监管制度、填报说明和统计报表的可信 RAG 问答。评测目标是验证 500 份官方附件入库、300 条官方 QA、证据引用、表格取数、拒答与 CPU/GPU 性能边界，并补充自制数据集的可复现评测入口。

2. 系统及技术方案概述

系统采用 FastAPI、SQLite 元数据、Qdrant 向量索引、BGE-M3 embedding、BGE reranker 和 OpenAI-compatible 大模型 API。回答链路遵循“检索到 chunk/表格证据才回答；依据不足则拒答”的约束，确定性表格题优先使用结构化单元格证据。

3. 评测环境

项目	值
操作系统/平台	Windows-11-10.0.26200-SP0
Python	3.13.12 (tags/v3.13.12:1cbe481, Feb 3 2026, 18:22:25) [MSC v.1944 64 bit (AMD64)]
Git commit	4e4a29cc7b46d7dd8d5c50a984de3d2784b7f4bf
项目根目录	D:\Agent-Project\ReguMate Agent
环境变量记录	仅记录是否配置 API Key，不输出密钥

4. 硬件与软件配置

已有性能基线文档记录：CPU 为 AMD Ryzen 9 8945HX，16 核/32 线程，内存约 34.1 GB；GPU 为 NVIDIA RTX 5070 Laptop GPU，8 GB 显存。phase1 QA 结果的资源采样峰值如下：

环境	CPU 峰值	RSS 峰值	CUDA allocated 峰值	CUDA reserved 峰值	来源
GPU	434.18%	4.22 GiB	1.07 GiB	1.09 GiB	data/evaluation/performance_experiments/phase1_gpu_full300/contest_qa_all_results.json
CPU	433.94%	0.63 GiB	-	-	data/evaluation/performance_experiments/phase1_cpu_full300/contest_qa_all_results.json

5. 模型、Embedding、数据库和检索参数

参数	GPU 记录	CPU 记录
selected_mode	gpu	cpu_balanced
backend	pytorch	pytorch
effective_cpu_cores	32	32
embedding_batch_size	4	4
rerank_batch_size	24	4
rerank_max_length	1024	1024
torch_num_threads	16	16
warmup_policy	background	background

Embedding/reranker 为本地 BGE 模型；.env 中的大模型 API 影响 query planning、答案生成和高风险语义核验。Qdrant collection 与 points 以 docs/evaluation/final_contest_report.json 的最终官方报告为准：regumate_chunks, 45,651 points。

6. 数据集说明

数据集	规模	用途	来源文件
官方附件	500 份	入库、解析、分块、索引完整性	data/contest_dataset/dataset/; data/contest_staging/
官方 QA	300 题	答案准确率、来源命中、分题型/难度、性能	data/contest_dataset/QA数据.xlsx
OOD 派生题	30 题	依据不足拒答	scripts/evaluate_contest_qa.py 从官方题派生
自制数据集	4 文档 / 8 题	功能覆盖与可复现样例	data/contest-data-self-made/qa/self_made_qa.jsonl

7. 500 份文档入库测试方案

入库评测读取 data/evaluation/performance_experiments/index_parse500.json。该文件记录 500 份文档的解析、分块、SQLite chunk 持久化、embedding 推理阶段耗时和按扩展名/解析器统计。完整 Qdrant 向量写入对比未在现有日志中同口径保存。

指标公式：入库成功率 = success / processed；平均每文档耗时 = total_elapsed_ms / processed 或原始 per_document_ms.average；阶段平均耗时直接读取 performance.stages 中的 avg_ms。

8. 入库测试结果

指标	结果
文档总数	500
成功数量	500
失败数量	0
入库/解析成功率	100.00%
Chunk 数	46577
表格单元格数	133001
Vector 数	0
总耗时	2066.75 s
平均每文档耗时	4.11 s
解析阶段平均耗时	1.88 s
分块阶段平均耗时	1.69 s
Embedding 阶段平均耗时	3.89 s
SQLite chunk 持久化平均耗时	0.50 s

按文件格式统计：

格式	处理	成功	失败	Chunk	Cells
.doc	32	32	0	1365	0
.docx	34	34	0	5360	0
.pdf	45	45	0	3849	0
.xls	232	232	0	26752	87359
.xlsx	157	157	0	9251	45642

9. 300 条 QA 评测方案

官方 QA 使用 scripts/evaluate_contest_qa.py 调用后端 /api/qa/ask，并按 source_type、qa_type、difficulty 切片统计。phase1 结果额外捕获后端性能配置、资源采样、引用、context_package 与 manifest_evidence。

核心公式：答案准确率 = answer_correct=True 题数 / 有效题数；来源命中率 = source_hit=True 题数 / 有效题数；引用覆盖率 = 非拒答题 citation_count>0 题数 / 非拒答题数；平均响应时间 = elapsed_ms 平均值。

10. QA 总体结果

指标	官方最终 GPU	phase1 GPU	phase1 CPU
题数	300	300	300
完成题数	300	300	300
错误数	0	0	0

指标	官方最终 GPU	phase1 GPU	phase1 CPU
答案准确率	100.00%	100.00%	100.00%
来源命中率	100.00%	100.00%	100.00%
引用覆盖率	100.00%	100.00%	100.00%
Grounding 通过率	100.00%	100.00%	100.00%
Excel 单元格召回率	100.00%	100.00%	100.00%
文本证据覆盖率	86.00%	86.75%	86.75%
文本证据 bigram recall	86.32%	86.29%	86.29%

11. 分题型评测结果

切片	题数	正确数	准确率	平均耗时	P95
单事实检索	134	134	100.00%	3.59 s	7.03 s
多事实检索	66	66	100.00%	4.04 s	6.96 s
表格取数	34	34	100.00%	0.40 s	0.81 s
表格比较	33	33	100.00%	0.41 s	0.68 s
表格计算	33	33	100.00%	0.47 s	0.63 s

12. 分难度评测结果

切片	题数	正确数	准确率	平均耗时	P95
中等	99	99	100.00%	2.29 s	4.17 s
困难	99	99	100.00%	2.85 s	5.39 s
简单	102	102	100.00%	2.76 s	4.41 s

13. 检索效果评测

指标	结果	说明
来源命中率	100.00%	source_hit=True / 总题数
可评估题数	293	来自 phase1_gpu_full300 的 context_package 与 evidence_manifest_seed.json
可评估 aspect 数	469	仅统计 evidence manifest 中有 acceptable_chunk_ids 的标准 aspect
Case Recall@1	88.05%	全部标准 aspect 均在该题已保存候选 Top-1 内命中
Case Recall@3	92.49%	全部标准 aspect 均在该题已保存候选 Top-3 内命中
Case Recall@5	98.29%	全部标准 aspect 均在该题已保存候选 Top-5 内命中
Aspect Recall@1	92.54%	标准 aspect 粒度 Top-1 命中
Aspect Recall@3	95.31%	标准 aspect 粒度 Top-3 命中
Aspect Recall@5	98.93%	标准 aspect 粒度 Top-5 命中
最终上下文 Case Recall	100.00%	acceptable chunk 进入最终 prompt 上下文

检索 TopK 指标由新增脚本 scripts/evaluate_retrieval_from_results.py 基于已保存 context_package.retrieval_summary.aspect_retrievals[].retrieved_chunks 和 data/evaluation/performance_experiments/evidence_manifest_seed.json 离线重算；14 道无 acceptable chunk 的 needs_review 题未纳入 Recall@K 分母。逐题明细见 outputs/evaluation/retrieval_details.jsonl。

14. 证据引用与可追溯性评测

指标	结果
引用覆盖率	100.00%
Grounding 通过率	100.00%
Reviewed citation accuracy	100.00%
Reviewed citation completeness	100.00%
无效引用案例数	0
缺少行内引用案例数	0

指标	结果
Unsupported entity 案例数	0

15. 表格取数能力评测

指标	结果
Excel 题数	100
Excel 准确率	100.00%
Excel 单元格召回率	100.00%
表格取数准确率	100.00%
表格比较准确率	100.00%
表格计算准确率	100.00%

16. 拒答与幻觉抑制评测

指标	GPU OOD	CPU OOD
题数	30	30
拒答准确率	100.00%	100.00%
答案准确率	100.00%	100.00%
幻觉率代理指标	0.00%	0.00%

说明：现有数据没有人工逐条幻觉标注；报告使用 key_entity_error_rate 作为代理指标，并同时报告 OOD 拒答准确率。

17. 自制数据集评测

项目	结果
数据集名称	contest-data-self-made
文档数	4
QA 题数	8
题型分布	业务流程题:1；依据不足拒答题:1；制度事实题:1；条款口径题:1；条款阈值题:1；表格取数题:1；表格计算题:1；跨文件场景判断题:1
难度分布	中等:2；简单:5；越界/依据不足:1
API 实测模式	offline_artifact
API 准确率	未采集
数据合规	无敏感客户数据: True；无真实银行交易数据: True

自制数据集标准答案由自制监管制度、填报说明和 CSV 报表中的显式事实人工编写。当前离线报告未连接后端，因此自制 QA 准确率、耗时和引用命中率未实测。

18. 性能与响应时间评测

环境	平均	P50	P90	P95	最大
GPU	2.63 s	2.75 s	4.18 s	4.73 s	47.86 s
CPU	8.85 s	9.59 s	18.44 s	20.09 s	28.10 s

19. GPU 与 CPU 问答性能对比

指标	GPU	CPU	对比
平均响应时间	2.63 s	8.85 s	CPU/GPU = 3.36x
P95	4.73 s	20.09 s	
准确率	100.00%	100.00%	一致

20. 典型正确案例

正确回答且证据准确

- 问题：根据 Excel 附件《2023年10月人身险公司经营情况表》（工作表：人身保险公司（月度）），“原保险保费收入”在“本年累计/截至当期”口径下的数值是多少？
- 标准答案：A
- 系统答案：答案为 31739.18。依据表格证据，核验值为 31739.18。[1]
- 引用来源：145_2023年10月人身险公司经营情况表_2023年10月人身险公司经营情况表.xlsx
- 评分结果：answer_correct=True, source_hit=True, citation_count=1
- 错误类型：无
- 原始运行：phase1_gpu_full300 / Q001

21. 典型错误案例

本次汇总的官方 300 题 phase1 GPU/CPU 与 OOD 结果中未发现 answer_correct=False 的错误案例，outputs/evaluation/error_cases.jsonl 为空。用户要求列出的“答案正确但引用不准确、检索正确但生成错误、检索未命中、表格行列或期间识别错误、新旧文件版本混淆、错误拒答、发生幻觉”等类别，在现有可核验结果中未出现，不能构造示例。

22. 错误原因分类

错误类型	数量	说明
答案错误	0	来自 qa_details.jsonl
请求/程序错误	0	来自 error 字段
引用不准确	0	来自 grounding_validation
缺少行内引用	0	来自 grounding_validation
Unsupported entity	0	来自 grounding_validation

23. 当前系统已知问题

- 500 文档完整 GPU/CPU 向量入库对比未找到可核验结果，只能报告 CPU 解析/分块基线。
- 已新增离线检索指标采集脚本，可基于已保存候选和 evidence manifest 计算 Recall@1/3/5；但该结果仍依赖保存下来的最终候选列表，不等价于重新请求 Qdrant 的在线检索实验。
- 自制数据集目前默认产物是离线设计报告，未连接后端时没有 API 实测指标。
- 幻觉率没有人工逐条标注，当前只报告 key_entity_error_rate 代理指标和 grounding 结果。

24. 评测局限性

官方 300 题能覆盖 Excel、Word、PDF、表格取数/比较/计算和文本证据，但仍是固定题集；OOD 为派生 30 题，不代表所有越界问题。资源采样来自后端内部采样，不等价于整机监控。外部 LLM API 网络耗时未独立拆分。

25. 改进方向

- 在入库脚本中保存 parse、chunk、embedding、Qdrant upsert、SQLite persist 的完整阶段耗时和资源峰值。
- 在 QA 在线评测中继续保存完整候选排名和 evidence manifest 版本，以便 Recall@1/3/5 与 rerank retention 可重复复核。
- 对自制数据集连接后端补跑，并保留结果 JSON/JSONL。
- 增加人工抽样复核文件，区分答案错误、引用错误、检索错误和幻觉。

26. 结论

可核验的官方最终 GPU 报告显示 300/300 完成、答案准确率 100.00%、来源命中率 100.00%。phase1 GPU/CPU 300 题均为 100.00% 准确率；GPU 平均响应 2.63 s，CPU 平均响应 8.85 s。500 文档 CPU 解析/分块基线为 500/500 成功，完整 GPU/CPU 向量入库对比需补跑。

27. 复现方法

从已有结果生成统一评测产物和报告：

```
python scripts\generate_evaluation_report.py --output-dir outputs\evaluation --output docs\系统评测报告.md
```

只汇总入库结果：

```
python scripts\evaluate_ingestion.py --result data\evaluation\performance_experiments\index_parse500.json --output-dir outputs\evaluation
```

从已有 QA 结果生成 QA 指标：

```
python scripts\evaluate_qa.py --from-existing --output-dir outputs\evaluation
```

连接运行中后端重新执行官方 QA：

```
python scripts\evaluate_qa.py --run-backend-eval --dataset data\contest_dataset\QA数据.xlsx --base-url http://127.0.0.1:8000 --device cuda --split all --output-dir outputs\evaluation
```

自制数据集复现：

```
powershell -NoProfile -ExecutionPolicy Bypass -File .\scripts\run_self_made_evaluation.ps1  
python scripts\evaluate_custom_dataset.py --output-dir outputs\evaluation
```

CPU/GPU QA 对比：

```
python scripts\compare_cpu_gpu.py --output-dir outputs\evaluation
```

28. 实验结果文件索引

实验	原始结果文件	执行/生成脚本	说明
官方最终 300 QA	data/evaluation/contest_qa_test/20260716_173747/contest_qa_all_results.json	scripts/build_contest_report.py	官方最终口径
phase1 GPU 300 QA	data/evaluation/performance_experiments/phase1_gpu_full300/contest_qa_all_results.json	scripts/evaluate_contest_qa.py	完整引用/context/performance 结果
phase1 CPU 300 QA	data/evaluation/performance_experiments/phase1_cpu_full300/contest_qa_all_results.json	scripts/evaluate_contest_qa.py	CPU 问答性能
GPU OOD 30	data/evaluation/performance_baseline/gpu_20260718_182304/ood/contest_qa_ood_results.json	scripts/evaluate_contest_qa.py --split ood	拒答评测
CPU 解析/分块 500	data/evaluation/performance_experiments/index_parse500.json	scripts/ingest_contest_dataset.py	解析/分块/SQLite persist/embedding 阶段
自制数据集	data/contest-data-self-made/manifest.json	scripts/generate_self_made_artifacts.py	离线设计与 PDF/MD/JSON 产物
统一报告源	outputs/evaluation	scripts/generate_evaluation_report.py	本次派生输出目录